Deep Learning and Computer Vision

Relatório das Atividades 1 a 4

Gabriel Aguiar Aquino

11 de outubro de 2026

Sumário

Declaração de uso de inteligência artificial **3**

1 Introdução **4**
1.1 Ambiente de execução . . . 4
1.2 Organização do relatório . . . 4

2 Atividade 1 — Vision Transformer para Severidade de Acidentes **5**
2.1 Objetivo . . . 5
2.2 Dados . . . 5
2.3 Método . . . 6
2.4 Resultados . . . 6
2.5 Interpretabilidade: Attention Rollout . . . 7
2.6 Discussão . . . 8
2.7 Limitações . . . 8

3 Atividade 2 — Reconhecimento Semântico em Publicidade Visual com CLIP **10**
3.1 Objetivo . . . 10
3.2 Dados . . . 10
3.3 Método . . . 10
3.4 Resultados . . . 10
3.4.1 Escolha do limiar . . . 10
3.4.2 Ranking de conceitos (limiar 0,28) . . . 11
3.4.3 Busca semântica . . . 12
3.5 Discussão . . . 13
3.6 Limitações . . . 14

4 Atividade 3 — Classificador com CNN Pré-treinada **15**
4.1 Objetivo . . . 15
4.2 Dados . . . 15
4.2.1 Remoção de duplicatas . . . 15
4.3 Método . . . 16
4.4 Resultados . . . 16
4.5 Discussão . . . 18
4.6 Propostas de melhoria . . . 18
4.7 Limitações . . . 19

5 Atividade 4 — Estudos de Caso em Deep Learning **20**
5.1 Atividade 4.1 — Detecção de COVID-19 em radiografias 20
5.1.1 Cenário e objetivo 20
5.1.2 Diagnóstico do cenário original 20
5.1.3 Dados 21
5.1.4 Método 22
5.1.5 Imagens sintéticas 23
5.1.6 Resultados: Experimento A × Experimento B 24
5.1.7 Discussão 25
5.1.8 Plano integrado de melhorias 25
5.2 Atividade 4.2 — Transfer learning para análise de tráfego urbano . . 26
5.2.1 Cenário 26
5.2.2 Problemas e impacto operacional 26
5.2.3 Medidas corretivas 27
5.2.4 Por que 78% de acurácia não garante desempenho confiável . . 27
5.3 Limitações 27

Referências **29**

Declaração de uso de inteligência artificial

Este trabalho foi desenvolvido com o apoio de duas ferramentas de inteligência artificial generativa:

- **ChatGPT** (OpenAI), usado no **planejamento** das atividades;
- **Claude Code** (Anthropic), usado como assistente de programação e de redação.

Como as ferramentas foram utilizadas

- **Planejamento (ChatGPT):** apoio na interpretação dos enunciados e na organização das etapas de cada atividade.
- **Implementação (Claude Code):** geração e revisão do código dos notebooks (carregamento de dados, treinamento, avaliação e visualização), a partir dos enunciados das atividades.
- **Revisão metodológica (Claude Code):** identificação de erros e problemas metodológicos, como vazamento de dados, critérios de seleção de checkpoint e agrupamento de imagens quase idênticas.
- **Relatório (Claude Code):** organização e redação deste relatório a partir das saídas efetivamente registradas nos notebooks, além do script que consolida o relatório em PDF.

Responsabilidades do autor

- Execução dos notebooks no Google Colab e conferência das saídas.
- Revisão crítica do planejamento, do código, das análises e do texto, além das decisões finais sobre o que entra no trabalho.
- Responsabilidade integral pelo conteúdo entregue.

Integridade dos resultados

Todos os números, tabelas e figuras de resultados apresentados neste relatório foram extraídos das saídas das execuções dos notebooks; nenhum valor experimental foi produzido ou estimado pelas ferramentas de IA. Quando uma execução apresentou problema metodológico, o problema é relatado em vez de omitido.

1 Introdução

Este relatório reúne as quatro atividades práticas de Visão Computacional e Deep Learning desenvolvidas no repositório `computer-vision-p1`. Cada atividade foi implementada como um notebook executável no Google Colab e explora uma família diferente de técnicas.

Atividade	Tema	Técnica principal	Dataset
1	Classificação de severidade de acidentes	Vision Transformer (do zero e pré-treinado) e ResNet-18	Car Accidents and Deformation Dataset (CADD)
2	Reconhecimento semântico em publicidade	CLIP (ViT-B/32) em regime *zero-shot*	ADS-16
3	Classificador com CNN pré-treinada	ResNet-50 com extração de características	Images Dataset (7 classes)
4	Estudos de caso	ResNet-18 com transfer learning e GAN condicional; análise de transfer learning em tráfego urbano	COVID-19 Radiography Database

1.1 Ambiente de execução

Todos os notebooks foram executados no Google Colab com GPU NVIDIA Tesla T4, PyTorch 2.11 e torchvision 0.26 (CUDA 12.8). Os datasets são públicos e foram obtidos pela API oficial do Kaggle. Cada notebook fixa a semente 42 para Python, NumPy e PyTorch.

1.2 Organização do relatório

Cada capítulo segue a mesma estrutura: objetivo, dados, método, resultados e discussão crítica, incluindo as limitações. Os números citados são os registrados nas saídas dos notebooks versionados no repositório, e as figuras foram extraídas dessas mesmas saídas.

Ao longo do relatório, adota-se uma postura crítica em relação aos próprios resultados: métricas muito altas ou muito baixas são investigadas, e problemas de protocolo (por exemplo, seleção de modelo no mesmo conjunto usado para reportar o desempenho) são apontados explicitamente.

2 Atividade 1 — Vision Transformer para Severidade de Acidentes

Notebook: `atividade-1-projeto-livre/vit_accident_severity_colab.ipynb`.

2.1 Objetivo

Construir um pipeline de classificação de imagens em cinco níveis de severidade de acidentes de trânsito e comparar três modelos:

1. **ResNet-18** pré-treinada no ImageNet (baseline convolucional, *fine-tuning* completo);
2. **Vision Transformer (ViT) implementado e treinado do zero**;
3. **ViT-B/16 pré-treinado** no ImageNet-1k (*fine-tuning* completo).

Também se investiga a interpretabilidade do ViT por meio de **Attention Rollout** (Abnar & Zuidema, 2020), comparando os mapas de atenção com as *bounding boxes* anotadas.

2.2 Dados

O **Car Accidents and Deformation Dataset (CADD)** traz anotações no formato YOLO (detecção de objetos) em cinco classes: *Sem Acidente*, *Acidente Leve*, *Acidente Moderado*, *Acidente Severo* e *Perda Total*.

Rótulo por imagem. Como a tarefa é de classificação, cada imagem recebe a classe **mais severa** entre os objetos anotados (`label = max(class_ids)`). Essa é uma simplificação: uma imagem com um carro intacto e outro com perda total é rotulada como *Perda Total*.

Inspeção. Foram encontradas 1.221 imagens válidas com rótulo; duas imagens da validação original foram descartadas por não terem arquivo de rótulo.

Divisão com controle de vazamento. O dataset contém cópias aumentadas das mesmas fotos (sufixos como `_flip`, `_flip30`, `_flip70`). Na divisão original do dataset, **70 grupos** de imagens apareciam simultaneamente no treino e na validação, o que caracteriza vazamento. O notebook remove esses sufixos para obter um identificador de grupo (1.016 grupos) e refaz a divisão 80/20 **por grupo**, garantindo que nenhuma foto e suas variações apareçam nos dois conjuntos.

Classe	Treino	Validação
Sem Acidente	48	17
Acidente Leve	245	59
Acidente Moderado	253	78
Acidente Severo	163	40
Perda Total	271	47
Total	**980**	**241**

A classe *Sem Acidente* é a menos representada. Para compensar, a função de perda usa **pesos de classe** inversamente proporcionais à frequência (de 0,72 para *Perda Total* a 4,08 para *Sem Acidente*) e **label smoothing** de 0,1.

2.3 Método

Entrada de 224×224 com normalização do ImageNet. No treino, aplicou-se *data augmentation* com `RandomResizedCrop` (escala 0,7–1,0), espelhamento horizontal, rotação de ±15° e `ColorJitter`. Todos os modelos usam AdamW e mixed precision na GPU.

Modelo	Inicialização	Épocas	LR	Agenda de LR
ResNet-18	ImageNet	5	3e-4	Cosseno
ViT do zero (6 blocos, 6 cabeças, dim. 384, patch 16)	Aleatória	20	3e-4	Warmup linear (3 ép.) + cosseno
ViT-B/16	ImageNet-1k	10	1e-4	Warmup linear (2 ép.) + cosseno

O ViT do zero foi implementado explicitamente: *patch embedding* por convolução com *stride* igual ao *patch*, token `[CLS]`, *embeddings* posicionais aprendidos e blocos *pre-norm* com atenção multi-cabeça calculada como $\mathrm{softmax}(QK^\top/\sqrt{d_k})V$. Em todos os modelos, o melhor estado foi escolhido pela **macro F1 de validação**.

2.4 Resultados

Modelo	Melhor época	Acurácia	Macro precisão	Macro recall	Macro F1
ResNet-18 (ImageNet)	3	0,527	0,539	0,550	0,518
ViT do zero	19	0,253	0,316	0,290	0,253
ViT-B/16 (ImageNet-1k)	8	**0,568**	**0,578**	**0,606**	**0,576**

Como referências mínimas: um classificador que sempre prevê a classe mais frequente da validação (*Acidente Moderado*, 78 de 241) obtém **0,324** de acurácia, e o acaso com cinco classes fica em torno de 0,20.

F1 por classe do ViT-B/16 pré-treinado: *Sem Acidente* 0,571; *Leve* 0,617; *Moderado* 0,496; *Severo* 0,438; *Perda Total* 0,756.

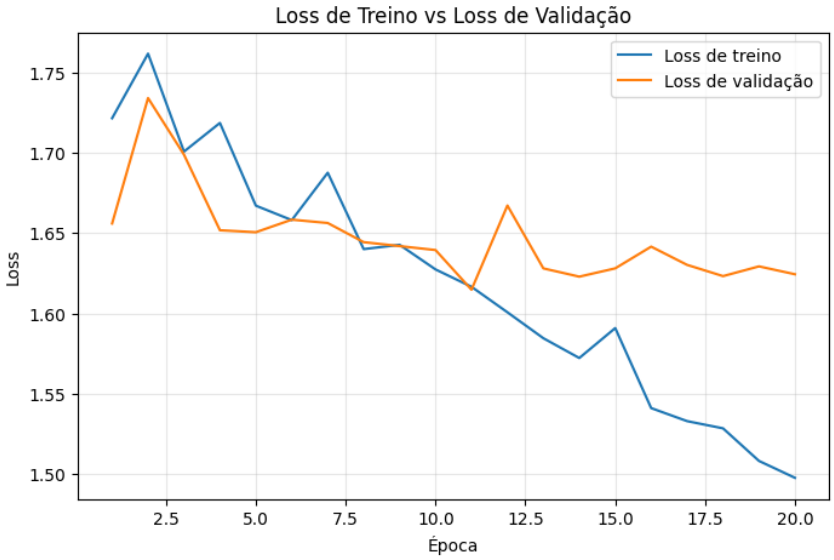


Figura 1: Loss de treino e de validação do ViT treinado do zero.

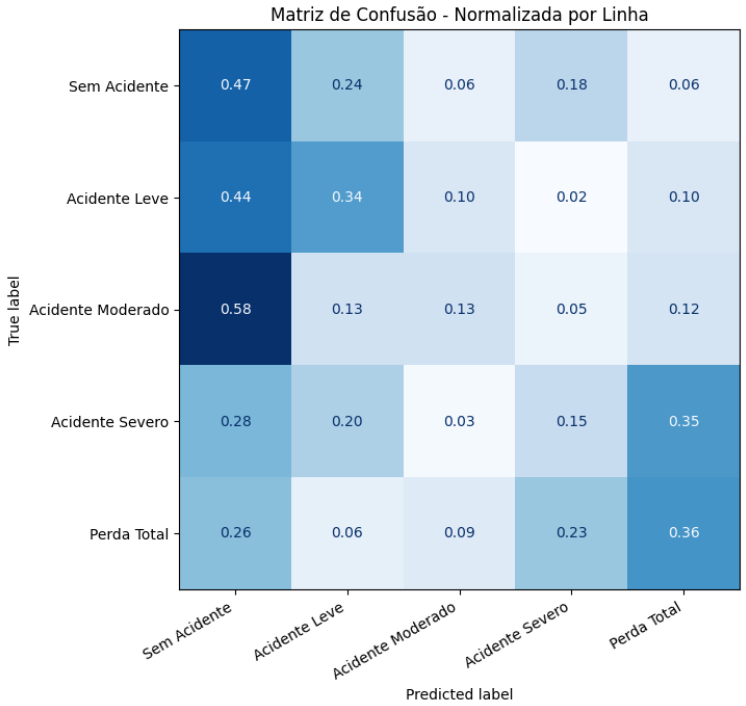


Figura 2: Matriz de confusão normalizada por linha do ViT treinado do zero (validação).

2.5 Interpretabilidade: Attention Rollout

O Attention Rollout propaga as matrizes de atenção (média das cabeças, com a identidade somada para representar as conexões residuais) por todas as camadas e mede quanto cada *patch* contribui para o token `[CLS]`. A figura compara a atenção da última camada, o rollout e as *bounding boxes* reais.

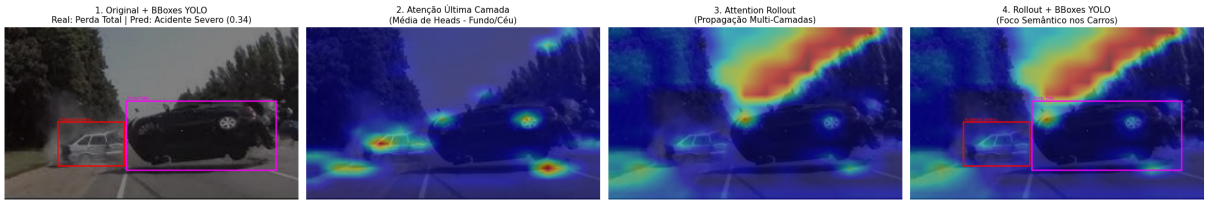


Figura 3: Attention Rollout do ViT treinado do zero em uma imagem de validação (rótulo real *Perda Total*, previsto *Acidente Severo*).

Leitura crítica. No exemplo acima, o rollout concentra a atenção na faixa de **céu e árvores** no canto superior direito, e não nos veículos delimitados pelas caixas. Isso é coerente com o baixo desempenho do ViT do zero: o modelo não aprendeu a focar nos danos e parece usar pistas de fundo. A legenda "Foco Semântico nos Carros" usada no notebook **não** é sustentada por esse exemplo. O rollout foi calculado apenas para o ViT do zero; o ViT-B/16 do torchvision não expõe os pesos de atenção, de modo que a análise não foi repetida para o melhor modelo.

2.6 Discussão

- **ViT do zero não aprende com ~1.000 imagens.** O ViT treinado do zero ficou **abaixo da baseline da classe majoritária** (0,253 contra 0,324). A acurácia de treino chegou a apenas 0,40 em 20 épocas, o que indica **subajuste**, e não sobreajuste. Transformers não têm os vieses indutivos das convoluções (localidade e equivariância à translação) e precisam de muito mais dados ou de pré-treinamento. A matriz de confusão mostra previsões espalhadas, com forte tendência a *Sem Acidente*, provavelmente puxada pelo maior peso dessa classe na perda.
- **Pré-treinamento é o fator decisivo.** O ViT-B/16 pré-treinado teve o melhor resultado (macro F1 0,576), seguido da ResNet-18 (0,518). Com pré-treinamento, o Transformer supera a CNN mesmo com poucos dados.
- **Sobreajuste nos modelos pré-treinados.** O ViT-B/16 atingiu 0,894 de acurácia no treino contra 0,568 na validação. A lacuna de ~33 p.p. sugere que regularização adicional, congelamento parcial ou mais dados ajudariam.
- **Classes intermediárias são as mais difíceis.** *Moderado* e *Severo* têm os menores F1, o que é esperado em uma escala ordinal com fronteiras subjetivas entre níveis vizinhos.

2.7 Limitações

1. **Seleção otimista do checkpoint.** O melhor estado de cada modelo foi escolhido pela macro F1 na **mesma validação** usada para reportar os resultados. Os números acima tendem, portanto, a ser otimistas; o correto seria separar uma validação interna para seleção ou usar um conjunto de teste independente.
2. **Uma única semente e uma única divisão.** Com 241 imagens de validação (17 de *Sem Acidente*), as métricas têm variância alta; diferenças de poucos pontos entre modelos não são conclusivas.
3. **Rótulo por agregação.** A regra "classe mais severa" ignora a presença de múltiplos veículos e transforma um problema de detecção em classificação.
4. **Agrupamento heurístico.** O controle de vazamento depende de sufixos de

nome de arquivo; cópias aumentadas com outros nomes não seriam detectadas.

5. **Reprodutibilidade parcial.** O notebook usa `cudnn.benchmark = True` e `cudnn.deterministic = False`, de modo que reexecuções na GPU podem variar ligeiramente.
6. **Interpretabilidade limitada.** Apenas três exemplos de rollout, todos do modelo mais fraco.

3 Atividade 2 — Reconhecimento Semântico em Publicidade Visual com CLIP

Notebook: `atividade-2-clip-publicidade/clip_semantic_advertising_colab.ipynb`.

3.1 Objetivo

Usar o **CLIP** (*Contrastive Language-Image Pre-training*, OpenAI) em regime estritamente **zero-shot** (sem treinamento, sem *fine-tuning* e sem atualização de pesos) para:

1. medir a presença de **20 conceitos semânticos** em anúncios publicitários e ordená-los por frequência;
2. implementar uma **busca semântica por texto** (*zero-shot retrieval*) e analisar oito consultas que variam de genéricas a abstratas.

3.2 Dados

O **ADS-16 Computational Advertising Dataset** foi baixado do Kaggle (`groffo/ads16-dataset`). A varredura recursiva encontrou **2.697 imagens** distribuídas em **260 pastas**. Há dois tipos de pasta: as numeradas de 1 a 20, com cerca de 15 anúncios cada, e pastas identificadas por código de usuário com sufixo `IM-POS`/`IM-NEG`, com 10 a 20 imagens. O notebook trata o nome da pasta como "categoria"; essa informação serve apenas para exibição, pois a tarefa não usa rótulos.

3.3 Método

Etapa	Implementação
Modelo	CLIP `ViT-B/32`, `model.eval()` e `torch.no_grad()` em toda a inferência
Embeddings de imagem	Encoder visual do CLIP, 512 dimensões, normalização L_2
Conceitos	20 conceitos (ex.: *a car*, *a person*, *text and logo*, *a luxury product*)
Prompt	Template contextual `"an advertisement featuring {}"`
Similaridade	$S = X_{img} X_{txt}^{\top}$ (cosseno, pois os vetores têm norma 1), matriz 2.697 × 20
Presença de conceito	Similaridade $\geq$ limiar operacional
Busca	Texto → embedding normalizado → produto escalar com todas as imagens → top-5

A similaridade de cosseno do CLIP **não é uma probabilidade**: ela mede proximidade angular no espaço multimodal, e qualquer limiar de "presença" é uma regra heurística.

3.4 Resultados

3.4.1 Escolha do limiar

Limiar	Conceitos por imagem (média)	Imagens sem nenhum conceito
0,20	7,89	12,3%
0,25	0,44	84,2%
0,28	**0,04**	**98,1%**
0,30	0,01	99,6%
0,35	0,00	100,0%

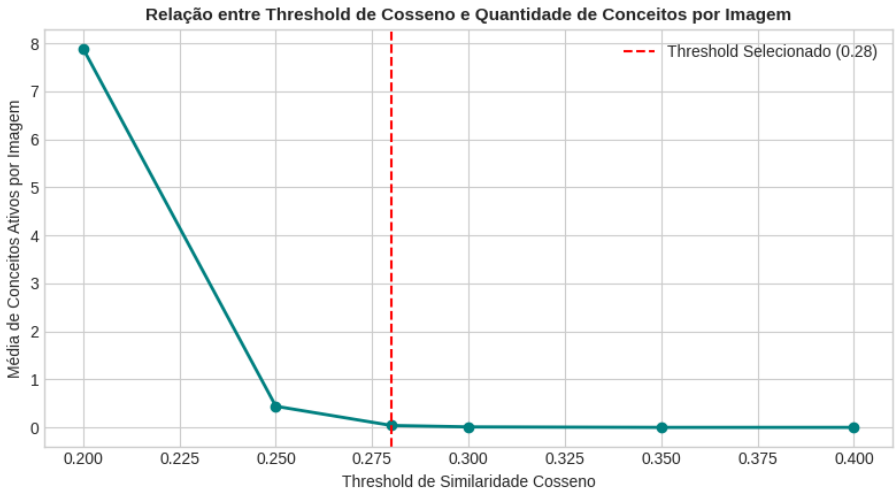


Figura 4: Média de conceitos detectados por imagem em função do limiar.

O notebook fixou o limiar em **0,28**. A curva mostra que as similaridades se concentram em uma faixa muito estreita (aproximadamente 0,18–0,34): entre 0,20 e 0,25 a média despenca de quase 8 para menos de 0,5 conceito por imagem.

3.4.2 Ranking de conceitos (limiar 0,28)

Posição	Conceito	Similaridade média	Imagens acima do limiar	Frequência
1	a fashion product	0,1996	18	0,67%
2	a person	0,2076	9	0,33%
3	a household product	0,1986	9	0,33%
4	a woman	0,1958	8	0,30%
5	a luxury product	0,2035	7	0,26%
…	…	…	…	…
20	a building	0,1765	0	0,00%

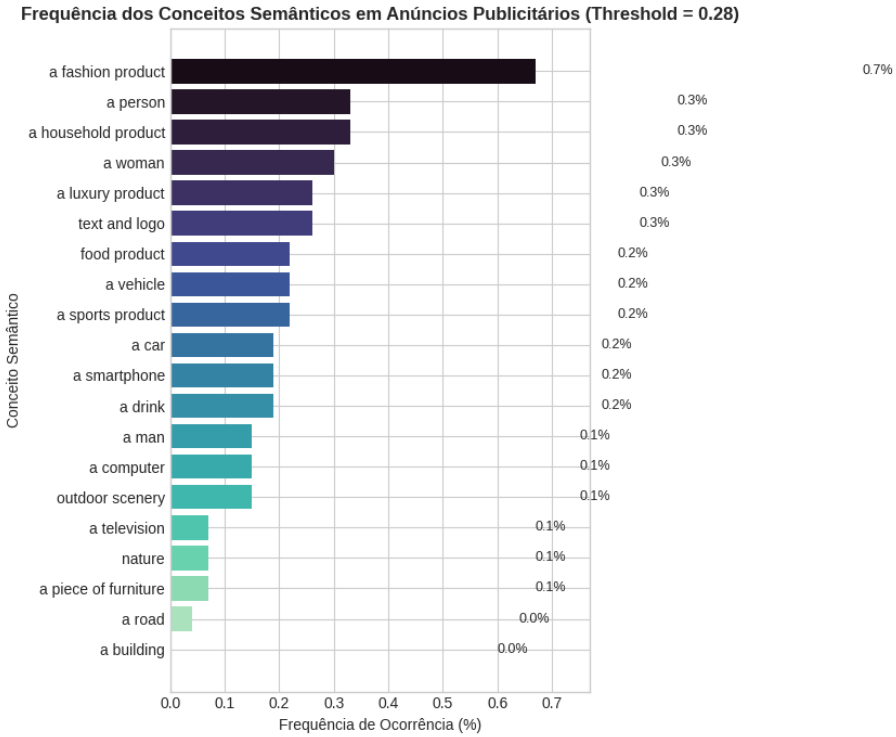


Figura 5: Frequência dos 20 conceitos no corpus com limiar 0,28.

3.4.3 Busca semântica

Foram executadas oito consultas: genéricas (*a product advertisement*), concretas (*a person*, *a car*), específicas (*a person using a smartphone*, *a luxury car in an urban environment*, *a cold drink being advertised*) e abstratas (*a premium lifestyle*, *an advertisement designed to attract attention*). Os escores do top-5 ficaram entre 0,264 e 0,338.



Figura 6: Top-5 para a consulta concreta “a car”.

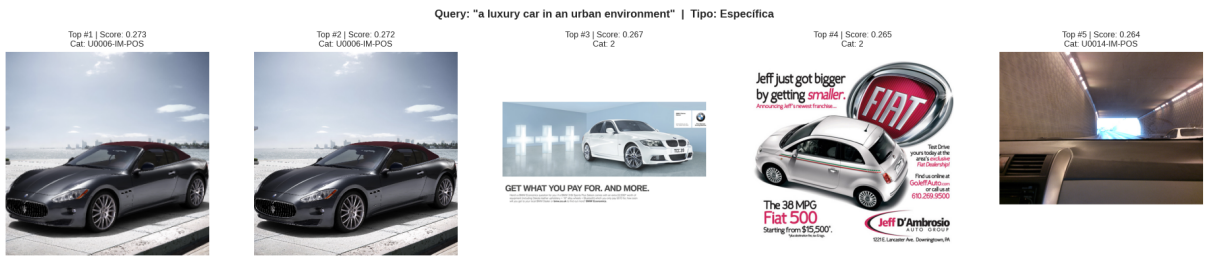


Figura 7: Top-5 para a consulta específica “a luxury car in an urban environment”.

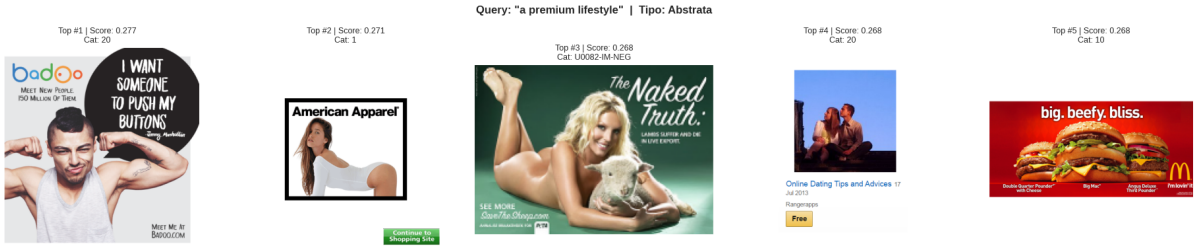


Figura 8: Top-5 para a consulta abstrata “a premium lifestyle”.

O que as figuras mostram (inspeção visual das saídas):

- **Consultas concretas de objeto funcionam bem.** Em *a car*, as cinco imagens são anúncios automotivos (Fiat 500, BMW, acessórios Raven, peças Renault). Uma delas, porém, é um anúncio **apenas de texto** (“Cheapest Car Parts Online”), sem nenhum carro: o CLIP também “lê” o texto da imagem.
- **Consultas específicas funcionam parcialmente.** *A luxury car in an urban environment* recupera um Maserati e um BMW, mas o fundo urbano raramente está presente; a 5ª imagem é o interior de um carro em um túnel.
- **Consultas abstratas são fracas.** *A premium lifestyle* retorna um anúncio do aplicativo de relacionamento Badoo, um da American Apparel, uma campanha da PETA, um anúncio de app de encontros e um do McDonald’s. Apenas parte desses resultados pode ser associada a “estilo de vida premium”.

3.5 Discussão

- **O limiar 0,28 é restritivo demais para contar conceitos.** Com ele, 98,1% das imagens não têm nenhum conceito, e o conceito mais frequente aparece em apenas 18 de 2.697 anúncios. O ranking passa a depender de poucas imagens e é instável: mudar a ordem de alguns poucos anúncios altera as posições. Note que a ordem por **similaridade média** é diferente (*a person* teria a maior média, 0,2076). Alternativas mais robustas seriam: limiar por conceito (por exemplo, um percentil da distribuição de cada conceito), atribuição *top-k* por imagem ou comparação relativa entre conceitos (softmax sobre os 20 *prompts*).
- **Fenômeno de *hubness*.** Um pequeno conjunto de imagens domina os resultados de consultas sem relação entre si. O anúncio do **Fiat 500** aparece no top-5 de **6 das 8** consultas (inclusive *a person* e *a person using a smartphone*), o do **Badoo** em 5 das 8, e o da **Kaspersky** em 4. Esses “hubs” são anúncios prototípicos (produto, pessoa e texto em destaque) que ficam próximos de muitos textos no espaço do CLIP. Isso explica por que a busca parece razoável em consultas genéricas e falha em consultas que exigem detalhes.
- **Efeito do template de prompt.** A função de busca aplica o mesmo template dos conceitos às consultas. Assim, *a product advertisement* se torna “an advertisement featuring a product advertisement”, e todas as consultas são puxadas na direção de “anúncio típico”, o que reforça o *hubness*. Comparar a busca com e sem o template seria um experimento simples e informativo.
- **Leitura de texto (OCR implícito).** O CLIP associa palavras escritas na imagem ao conceito, como em “Car Parts”, “Smartphone offers” e “Freshly Brewed Coffee” (este último aparece em *a cold drink being advertised*). Isso é útil para anúncios, mas também é uma vulnerabilidade conhecida a “ataques tipográficos”.

- **Duplicatas no corpus.** Imagens idênticas aparecem em posições consecutivas (o Maserati em *luxury car* e as latas de refrigerante em *cold drink*). Elas ocupam vagas do top-5 e inflam contagens; uma deduplicação por hash antes da indexação resolveria.
- **Divergência com a tabela qualitativa do notebook.** A tabela de "comportamento observado" do notebook descreve resultados mais favoráveis do que os exibidos nas figuras (por exemplo, "precisão de 100%" para *a person*, cujo top-5 inclui o anúncio do Fiat 500 sem pessoa visível). Este relatório adota a descrição baseada nas figuras efetivamente geradas.

3.6 Limitações

1. **Sem *ground truth*.** Não há anotação de presença de conceitos nem relevância por consulta; toda a avaliação é qualitativa. Uma rotulagem manual de uma amostra permitiria medir *precision@k*.
2. **Limiar heurístico global**, aplicado igualmente a conceitos com distribuições de similaridade diferentes.
3. **Vieses do pré-treinamento.** O CLIP herda associações culturais dos dados da web (o que é "luxo", "beleza", "atenção"), o que afeta diretamente as consultas abstratas.
4. **Embedding global.** Um único vetor por imagem não localiza objetos; composições como "pessoa *usando* smartphone" são resolvidas apenas aproximadamente.

4 Atividade 3 — Classificador com CNN Pré-treinada

Notebook: `atividade-3-cnn-pre-treinada/cnn_feature_extraction_colab.ipynb`.

4.1 Objetivo

Construir um baseline de **transfer learning por extração de características**: uma ResNet-50 pré-treinada no ImageNet é usada como extratora congelada, e apenas uma nova camada linear de classificação é treinada. O baseline não usa *data augmentation*, para servir de referência limpa às propostas de melhoria.

4.2 Dados

Images Dataset (Kaggle, `pavansanagapati/images-dataset`): 3.606 arquivos de imagem (`.jpg`, `.png` e `.bmp`) em 7 classes, sem nenhum arquivo corrompido.

4.2.1 Remoção de duplicatas

Uma primeira execução do notebook atingiu **100% de acurácia** na validação. Um resultado perfeito exige verificação, e a inspeção dos caminhos revelou duas estruturas paralelas, `data/<classe>` e `data/data/<classe>`, com as mesmas contagens por classe. A checagem por hash MD5 confirmou que o dataset vem **inteiramente duplicado**: na divisão por arquivo usada inicialmente, **568 das 722 imagens de validação (78,7%) tinham uma cópia exata no treino**. Aquela acurácia media memorização, não generalização.

O notebook foi corrigido para remover as repetições **antes** da divisão:

Etapa	Imagens
Arquivos válidos	3.606
Removidos por duplicata exata (mesmo MD5)	−1.842
Removidos por quase duplicata (dHash 16×16, distância ≤ 10 bits)	−19
Removidos por rótulo ambíguo (mesmo conteúdo em classes diferentes)	0
Imagens distintas mantidas	**1.745**

As 19 quase duplicatas são a mesma foto em outra resolução ou compressão; os pares foram conferidos visualmente.

Classe	Total	Treino	Validação
bike	360	288	72
cars	420	336	84
cats	202	162	40
dogs	201	161	40
flowers	210	168	42
horses	178	142	36

Classe	Total	Treino	Validação
human	174	139	35
Total	**1.745**	**1.396**	**349**

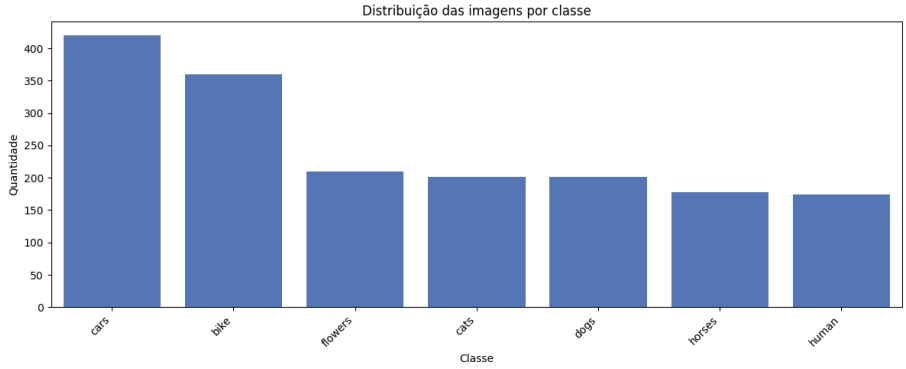


Figura 9: Distribuição das imagens distintas por classe.

A divisão é estratificada (80/20, semente 42). Ao final, o notebook verifica que nenhum MD5 se repete entre treino e validação e que a imagem de validação mais parecida com alguma do treino ainda está a 12 bits de distância no hash perceptual, acima do limiar de 10.

4.3 Método

Item	Configuração
Backbone	ResNet-50, pesos `ResNet50_Weights.DEFAULT` (ImageNet), **todas as camadas congeladas**
Cabeça	`Linear(2048 → 7)`: 14.343 parâmetros treináveis de 23,5 milhões
Pré-processamento	`Resize(224)`, `CenterCrop(224)`, normalização ImageNet; sem augmentation
Treinamento	Entropia cruzada, Adam (lr 1e-3) apenas na cabeça, lote 32, 10 épocas
Seleção	Melhor acurácia de validação

4.4 Resultados

Época	Loss treino	Acurácia treino	Loss validação	Acurácia validação
1	0,7637	0,8639	0,2347	0,9943
5	0,0463	0,9964	0,0487	0,9943
7	0,0340	0,9964	0,0375	**0,9971**
10	0,0200	0,9986	0,0291	0,9971

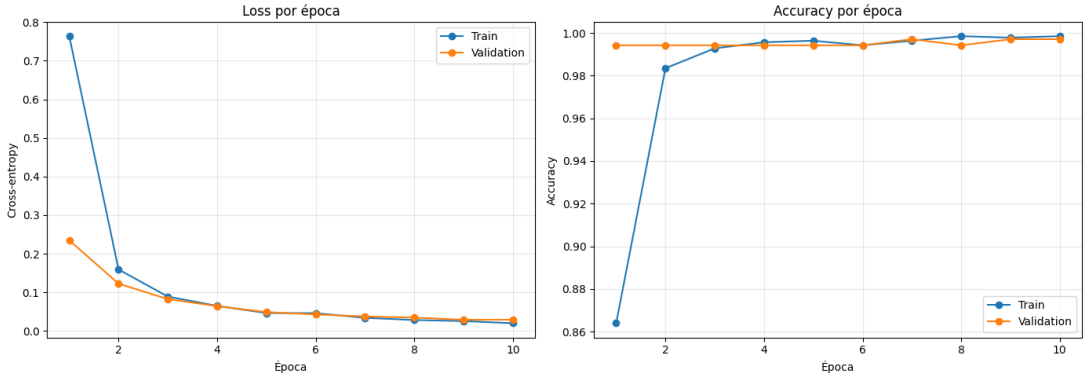


Figura 10: Curvas de loss e acurácia por época.

O melhor checkpoint (época 7) classificou corretamente **348 das 349 imagens** de validação: **acurácia de 0,9971**, com intervalo de confiança de Wilson (95%) de **[0,984; 0,9995]**. Todas as classes têm F1 de pelo menos 0,99. Precisão, recall e macro F1 arredondam para 1,00.

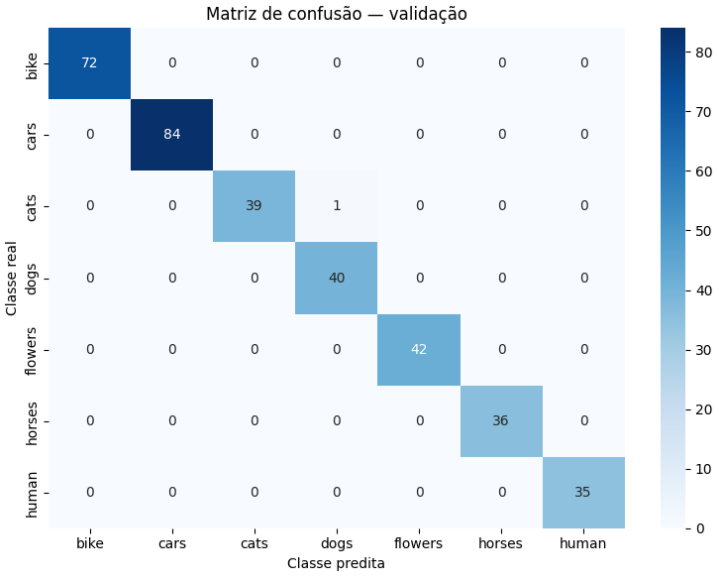


Figura 11: Matriz de confusão na validação.

O único erro é um **gato visto de costas**, sem o rosto visível, sobre um cobertor colorido, classificado como cachorro. É uma confusão plausível: sem a face, a pelagem e a postura são as principais pistas, e elas são compartilhadas pelas duas classes.

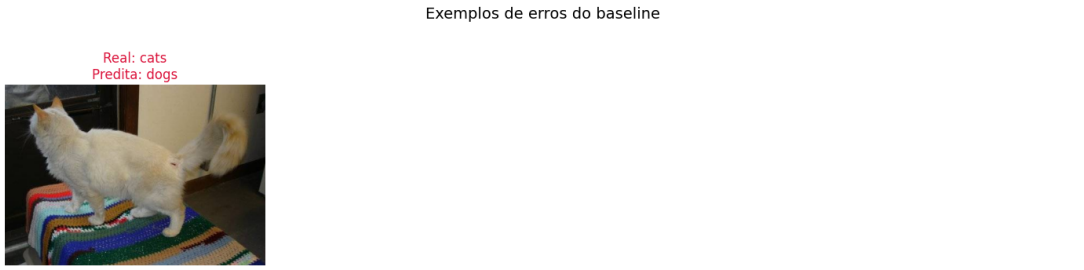


Figura 12: Única classificação incorreta da validação.

4.5 Discussão

- **A tarefa é fácil para features do ImageNet.** As sete classes (bicicletas, carros, gatos, cães, flores, cavalos e pessoas) correspondem a conceitos amplamente representados no pré-treinamento e são linearmente separáveis no espaço de 2.048 dimensões da ResNet-50. A acurácia de validação já é de 0,994 na primeira época.
- **A correção mudou pouco o número, mas mudou o que ele significa.** A acurácia caiu de 1,000 para 0,997. A diferença é pequena porque o problema é fácil, mas o novo valor mede generalização para imagens nunca vistas, enquanto o anterior era dominado por cópias do treino. A validação ficou menor (349 contra 722 imagens), e o intervalo de confiança reflete isso.
- **Não há sinal de sobreajuste.** A loss de validação acompanha a de treino, e a lacuna de acurácia é inferior a 0,2 p.p.
- **Lição metodológica.** Deduplicar antes de dividir deve ser rotina, sobretudo quando o resultado é "bom demais".

4.6 Propostas de melhoria

O notebook discute técnicas para experimentos posteriores, mantendo o baseline intocado:

Técnica	Benefício esperado	Risco
Augmentation geométrica (flip horizontal, rotações e crops pequenos)	Variedade de enquadramento; menos sobreajuste	Alterar a semântica de objetos orientados
Augmentation de cor (`ColorJitter` conservador)	Robustez a iluminação e câmera	Apagar pistas de cor relevantes
Variação de escala (`RandomResizedCrop` moderado)	Robustez a distância e enquadramento	Cortar o objeto
Normalização ImageNet	Compatibilidade com o pré-treinamento	Já utilizada; não é augmentation

Com um baseline de 99,7%, o ganho dessas técnicas não é mensurável nesta validação: restaria no máximo um acerto a conquistar. Para avaliá-las, seria preciso

um conjunto mais difícil, por exemplo com imagens de outra fonte, objetos parcialmente visíveis ou fundos complexos.

4.7 Limitações

1. O checkpoint foi selecionado pela acurácia na mesma validação usada para reportar o resultado. O efeito aqui é pequeno, pois as épocas 7 a 10 variam em uma única imagem, mas o protocolo correto separa uma validação interna.
2. Uma única semente e nenhum conjunto de teste independente.
3. A validação vem da mesma fonte do treino; o desempenho em imagens de outras origens não foi medido.
4. A deduplicação por hash perceptual não detecta fotos diferentes da mesma cena ou do mesmo animal.

5 Atividade 4 — Estudos de Caso em Deep Learning

Notebook: `atividade-4-estudos-de-caso/covid_cgan_case_study_colab.ipynb`.

5.1 Atividade 4.1 — Detecção de COVID-19 em radiografias

5.1.1 Cenário e objetivo

O enunciado descreve um classificador de radiografias de tórax com 1.200 imagens (840 *Normal*, 240 *Viral Pneumonia*, 120 *COVID-19*). Esse classificador usa uma ResNet-18 treinada do zero, SGD com taxa de aprendizado fixa de 0,01, 15 épocas, nenhum *data augmentation*, divisão 80/20 não estratificada e avaliação apenas por acurácia. Os resultados relatados no cenário foram 93% de acurácia no treino e 61% na validação, e a equipe clínica percebe que o modelo "ignora" os casos de COVID-19. Esses números pertencem ao enunciado e não foram reproduzidos aqui.

O objetivo é montar um experimento controlado com a mesma composição de classes e testar se imagens sintéticas de COVID-19, geradas por uma **GAN condicional (cGAN)**, melhoram a detecção da classe minoritária. A métrica primária é o **recall de COVID-19**, $TP/(TP+FN)$, sempre lida em conjunto com a precisão, o F1, a macro F1 e a matriz de confusão.

5.1.2 Diagnóstico do cenário original

#	Problema	Status	Consequência
1	Desbalanceamento (70/20/10%)	Comprovado	Prever sempre *Normal* já rende 70% de acurácia; muitos falsos negativos de COVID
2	Divisão não estratificada	Comprovado	Validação com poucos casos de COVID; recall instável
3	ResNet-18 do zero com ~960 imagens	Comprovado	Memorização, coerente com a lacuna de 32 p.p. entre treino e validação
4	Sem *data augmentation*	Comprovado	Menor robustez a posicionamento e exposição
5	Taxa de aprendizado fixa, sem ajuste	Comprovado	Convergência subótima; a última época pode não ser a melhor
6	Apenas acurácia global	Comprovado	Esconde o recall quase nulo da classe de interesse
7	Sem conjunto de teste independente	Comprovado	Estimativas otimistas
8	Vazamento entre pacientes	Risco	Métricas infladas se o mesmo paciente estiver nos dois conjuntos
9	Atalhos visuais (fonte, equipamento, marcações)	Risco, com indício nos metadados	O modelo pode aprender a origem da imagem, e não a doença
10	Sem validação externa	Comprovado	Generalização desconhecida para outros hospitais e populações

5.1.3 Dados

O **COVID-19 Radiography Database** foi baixado pela API do Kaggle sem credenciais. Considerando apenas as três classes de interesse, havia 15.153 imagens PNG de 299×299 pixels: 10.192 *Normal*, 1.345 *Viral Pneumonia* e 3.616 *COVID*. Nenhuma estava corrompida, e 54 duplicatas exatas (MD5) foram removidas antes da seleção. Os metadados **não** trazem identificador de paciente, mas revelam a **fonte** de cada imagem:

Fonte	COVID	Normal	Viral Pneumonia
`kaggle.com`	0	10.192	1.345
`bimcv.cipf.es`	2.474	0	0
Outras (GitHub, Eurorad, SIRM)	1.142	0	0

Todas as imagens de COVID vêm de repositórios diferentes dos usados para *Normal* e *Viral Pneumonia*. Classe e origem estão, portanto, completamente confundidas, o que torna real o risco de o classificador aprender a "assinatura" da fonte (equipamento, pós-processamento, marcações) em vez de achados clínicos.

A amostra experimental (840/240/120) foi sorteada com semente fixa. A proporção 70/20/10 foi imposta pelo cenário e difere da distribuição original (67/9/24).

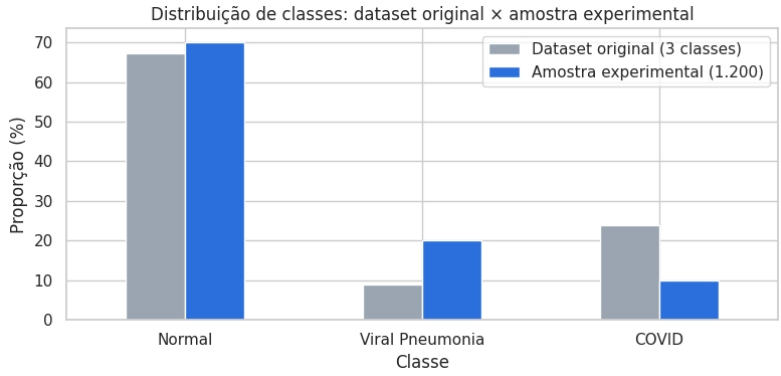


Figura 13: Distribuição de classes: dataset original × amostra experimental.

Divisão com controle de vazamento. Como não há ID de paciente, a divisão por paciente não foi possível. Como mitigação, imagens quase idênticas foram agrupadas por hash perceptual (dHash 16×16, distância de Hamming ≤ 10 bits) antes da divisão. Nenhum par atingiu o limiar (a menor distância entre conjuntos foi de 12 bits), de modo que cada imagem formou seu próprio grupo. Uma primeira versão com hash 8×8 encadeou centenas de radiografias distintas em um único grupo e produziu uma validação com uma única imagem. O erro foi detectado nas saídas e corrigido, e o notebook passou a interromper a execução se os grupos ou a divisão fugirem do esperado.

Conjunto	Normal	Viral Pneu-monia	COVID	Total	Uso
Treino de ajuste	571	163	82	816	Treinar o classificador e a cGAN
Validação interna	101	29	14	144	Selecionar o checkpoint
Validação real	168	48	24	240	Apenas a avaliação final de A e B

5.1.4 Método

Classificador (idêntico nos Experimentos A e B). ResNet-18 pré-treinada no ImageNet com o backbone congelado (extração de características); apenas a camada final `Linear(512 → 3)` é treinada (1.539 parâmetros). Entrada de 224×224, canal cinza replicado em 3 canais, normalização do ImageNet. No treino, transformação afim moderada (rotação de ±7°, translação de 4%, escala 0,95–1,05), **sem espelhamento horizontal**, porque inverter a lateralidade cria anatomia implausível. Perda de entropia cruzada sem pesos de classe, Adam (lr 1e-3, *weight decay* 1e-4) com decaimento cosseno, lote 32, 15 épocas. O checkpoint é escolhido pela **macro F1 na validação interna**, critério fixado antes do treinamento. A mesma semente garante inicialização idêntica nos dois experimentos, o que foi conferido pela soma dos pesos iniciais da camada final.

GAN condicional. Arquitetura no estilo DCGAN em 64×64, treinada **somente** com o treino de ajuste (a ausência de imagens de validação é verificada por *assert*), com amostragem balanceada por classe.

Componente	Configuração
Gerador	$z \in \mathbb{R}^{100}$ + *embedding* da classe (50) → Linear → 512×4×4 → 4 ConvT (BN + ReLU) → 1×64×64, Tanh
Discriminador	Imagem + mapa da classe (2 canais) → 4 Conv com normalização espectral e LeakyReLU → Linear
Perda	BCE com logits (não saturante), *label smoothing* de 0,9 no rótulo real
Otimização	Adam, lr 2e-4, $\beta = (0{,}5;\ 0{,}999)$, lote 64, 400 épocas (4.800 iterações, 9 min na T4)

Foram geradas **120 imagens sintéticas de COVID-19**. O Experimento B usa o mesmo treino real do A, acrescido dessas imagens, o que eleva a classe COVID de 82 para 202 exemplos (21,6% do treino).

5.1.5 Imagens sintéticas

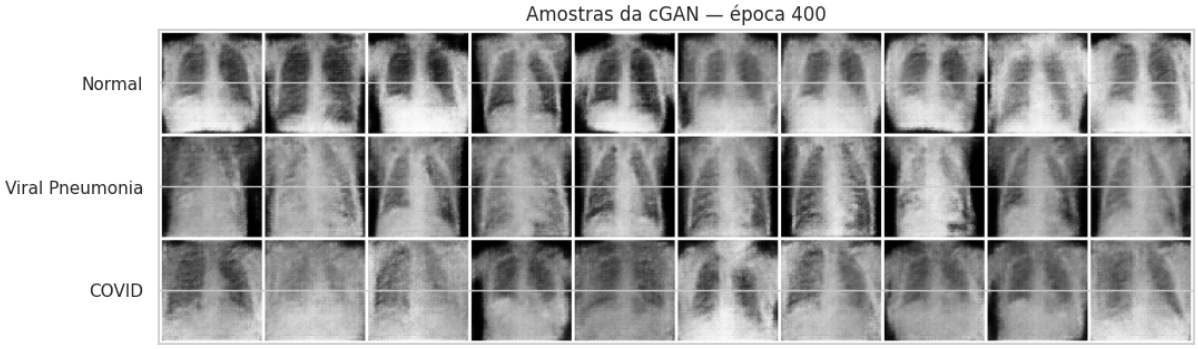


Figura 14: Amostras da cGAN na época 400, com ruído fixo (linhas = classe condicionante).



Figura 15: Sintéticas de COVID-19 (acima) e reais de COVID-19 do treino reduzidas para 64×64 (abaixo).

Indicador (64×64)	Sintéticas	Reais (COVID)	Razão
Distância média entre pares (diversidade)	12,78	16,38	0,78
Distância mediana à imagem real mais próxima	7,10	8,85	0,80
Desvio-padrão da intensidade	0,198	0,234	—
Pares de sintéticas quase idênticos	0	—	—

Inspeção. As sintéticas reproduzem a forma geral do tórax (campos pulmonares escuros, mediastino claro e bordas escuras), mas são borradas, têm textura granulada típica de convoluções transpostas e não mostram costelas nem clavículas nítidas. As sintéticas de COVID são, em geral, mais “lavadas” e difusas do que as das outras classes. Isso pode refletir as opacidades presentes nos exemplos reais, mas também pode ser apenas perda de contraste: a variância de intensidade é menor que a das reais. A diversidade é cerca de 22% menor que a das imagens reais (possível colapso parcial de modos), e não há sinal de cópia direta do treino. A partir da época ~250, a saída do discriminador para imagens reais e falsas se afasta progressivamente, indício de que ele começa a sobreajustar o pequeno conjunto real. **Nenhuma imagem sintética foi avaliada por radiologista, e aparência plausível não equivale a validade clínica.**

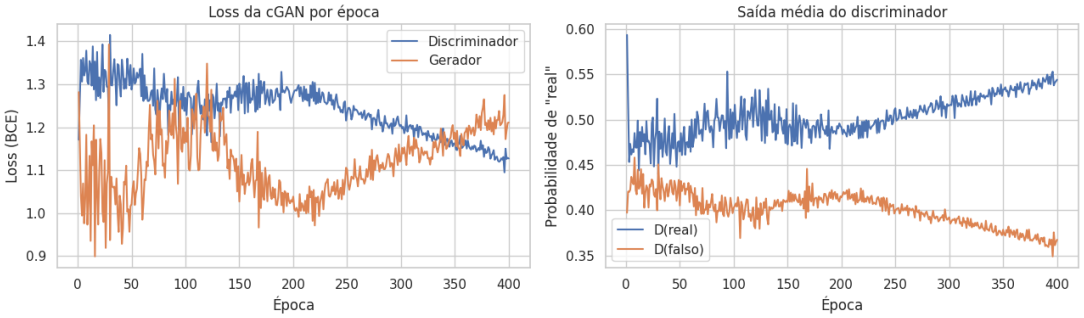


Figura 16: Perdas da cGAN e saída média do discriminador por época.

5.1.6 Resultados: Experimento A × Experimento B

Ambos os modelos foram avaliados uma única vez na validação real (240 imagens reais, 24 de COVID-19).

Métrica	Experimento A	Experimento B	Diferença
Acurácia global	0,863	0,883	+2,1 p.p.
Macro F1	0,663	0,736	+7,2 p.p.
Recall COVID-19	**0,125** (3/24)	**0,250** (6/24)	**+12,5 p.p.** (+100% relativo)
Precisão COVID-19	1,000	1,000	0,0 p.p.
F1-score COVID-19	0,222	0,400	+17,8 p.p.
Falsos negativos COVID	21	18	−3
Falsos positivos COVID	0	0	0
Checkpoint (época)	10	13	—

A diferença absoluta de recall é de **12,5 pontos percentuais**. A diferença relativa (+100%) parece grande apenas porque a base é muito baixa: corresponde a **três casos adicionais** detectados.

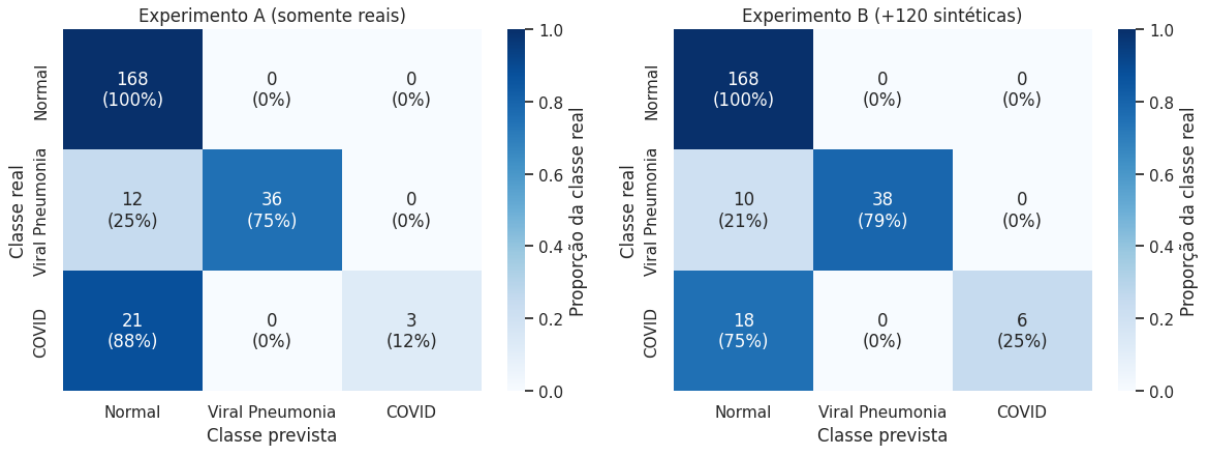


Figura 17: Matrizes de confusão na validação real.

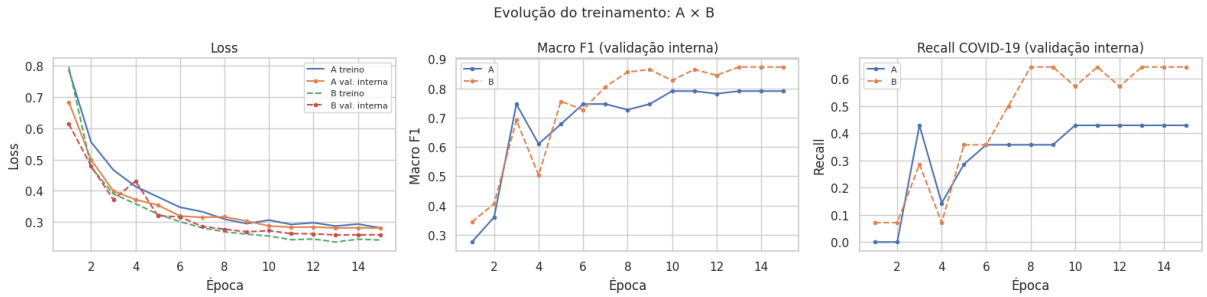


Figura 18: Evolução do treinamento: loss, macro F1 e recall de COVID na validação interna.

Incerteza. Com 24 casos positivos, cada caso vale 4,2 p.p. de recall. Os intervalos de Wilson (95%) se sobrepõem amplamente: A em [0,043; 0,310] e B em [0,120; 0,449]. O *bootstrap* pareado (2.000 reamostragens) dá IC95% de **[+0,0; +28,6] p.p.** para a diferença de recall e de [+0,010; +0,144] para a diferença de macro F1. O recall de B supera o de A em 95% das reamostragens.

5.1.7 Discussão

1. **A geração sintética aumentou o recall de COVID-19?** Nesta execução, sim: de 0,125 para 0,250 (+12,5 p.p.), com 18 em vez de 21 falsos negativos. Na validação interna, o efeito foi semelhante (recall de 0,43 para 0,64 e macro F1 de 0,79 para 0,87).
2. **Houve perda de precisão ou aumento de falsos positivos?** Não. Os dois modelos nunca previram COVID para imagens de outras classes (precisão de 1,0). O ganho não veio de "chutar COVID" com mais frequência.
3. **A acurácia global melhorou?** Ligeiramente (+2,1 p.p.). Também melhorou o recall de *Viral Pneumonia* (de 0,750 para 0,792).
4. **Há melhor equilíbrio entre classes?** Moderadamente: a macro F1 subiu 7,2 p.p. Ainda assim, **75% dos casos de COVID continuam classificados como *Normal***, e nenhum foi confundido com *Viral Pneumonia*. O desempenho na classe de interesse permanece clinicamente inaceitável.
5. **A qualidade das sintéticas explica os resultados?** Em parte. As sintéticas aumentam o peso da classe COVID na perda, de 10% para 22% do treino. Parte do ganho pode vir apenas desse **rebalanceamento**, que pesos de classe ou reamostragem também produziriam, e não de informação visual nova. Há ainda o risco de um atalho "imagem borrada ⇒ COVID", já que as sintéticas têm 64×64 pixels e são ampliadas para 224×224. Como a validação contém apenas imagens reais, esse atalho não explica diretamente os acertos, mas pode limitar o ganho.
6. **A evidência é robusta?** Não. O intervalo de confiança da diferença de recall encosta em zero, há uma única semente e uma única divisão, não há teste externo, e a confusão entre classe e fonte dos dados impede afirmar que o modelo reconhece a doença. O resultado é um **indício favorável e preliminar**, não uma conclusão.

5.1.8 Plano integrado de melhorias

Baixo custo (próximo experimento, sem novos dados):

1. Repetir A e B com várias sementes e com validação cruzada estratificada, reportando média, desvio e intervalos de confiança.
2. Comparar B com alternativas baratas de balanceamento: *class weights* e `WeightedRandomSampler`. Se igualarem o ganho, a cGAN não se justifica.
3. Fazer análise de limiar e calibração (curvas PR, *temperature scaling*). Com precisão de 1,0, há margem para reduzir o limiar de COVID e trocar alguns falsos positivos por menos falsos negativos.
4. Fazer *fine-tuning* parcial (descongelar a `layer4`), já que features do ImageNet não foram aprendidas em radiografias.
5. Investigar atalhos: Grad-CAM, treino com pulmões segmentados (máscaras do próprio dataset) e um classificador que tente prever a **fonte** da imagem.
6. Melhorar a cGAN: maior resolução, DiffAugment ou ADA, varredura de `N_SYNTHETIC` usando apenas a validação interna, e um controle que degrade imagens reais para 64×64.

Exigem novos dados ou validação clínica: divisão por paciente com identificadores reais; COVID e controles vindos **das mesmas instituições e equipamentos**; conjunto de teste independente e validação externa multicêntrica; revisão das previsões e das sintéticas por radiologistas; documentação de limitações e riscos (*model card*).

Nenhum modelo desta atividade está apto a apoiar diagnóstico médico.

5.2 Atividade 4.2 — Transfer learning para análise de tráfego urbano

5.2.1 Cenário

Uma ResNet-50 pré-treinada no ImageNet passa por *fine-tuning* com 800 *frames* rotulados de 12 câmeras urbanas, em três classes (tráfego livre, moderado e congestionado). O modelo atinge 78% de acurácia na validação, mas falha sistematicamente à noite, sob chuva e em ângulos de câmera não vistos no treino.

5.2.2 Problemas e impacto operacional

Problema	Impacto operacional
Poucos dados e baixa diversidade: ~67 *frames* por câmera, provavelmente concentrados em dias claros	O modelo falha justamente nas condições críticas para a gestão do tráfego (chuva, noite, incidentes)
Dependência entre *frames*: *frames* consecutivos da mesma câmera são quase idênticos; uma divisão aleatória coloca o "mesmo instante" no treino e na validação	Os 78% são otimistas e medem memorização da cena
Mudança de domínio: cada câmera tem perspectiva, lente e fundo próprios; noite (faróis, ruído) e chuva (reflexos, gotas) mudam a distribuição dos pixels	Degradação silenciosa ao instalar câmeras novas ou quando o clima muda
Sem avaliação por condição operacional	As falhas foram descobertas em operação, não na validação

Problema	Impacto operacional
Classes ambíguas: “moderado” é uma faixa contínua e depende do ângulo e da distância	Ruído de rótulo e indicadores inconsistentes entre câmeras
Apenas acurácia global	Pode esconder recall baixo de “congestionado”, a classe mais relevante
Sem avaliação temporal ou externa	Comportamento desconhecido em outras semanas, estações, obras ou câmeras
Sem adaptação de domínio nem monitoramento	A deriva (câmera reposicionada, lente suja) passa despercebida

5.2.3 Medidas corretivas

1. Separar treino e validação **por câmera**, com avaliação *leave-one-camera-out*, e usar **divisão temporal** para evitar *frames* vizinhos em conjuntos diferentes.
2. Coletar dados **reais** de noite, chuva e novos ângulos, com amostragem estratificada por câmera, período e clima, e aprendizado ativo para priorizar o que rotular.
3. Definir **critérios objetivos de rótulo** (ocupação, densidade por faixa, fila em uma região fixa), com exemplos de referência, dupla anotação e medida de concordância (kappa).
4. Reportar **precisão, recall e F1 por classe, macro F1 e matriz de confusão**, com destaque para o recall de “congestionado”.
5. **Avaliar por fatia**: câmera, período do dia e condição climática, com um desempenho mínimo exigido em cada fatia.
6. Usar ***data augmentation*** (brilho, gamma, ruído, desfoque, gotas e reflexos simulados) e **adaptação de domínio** (ajuste de BatchNorm ao domínio-alvo, DANN, pseudo-rótulos) quando justificadas, sempre validadas em dados reais.
7. **Monitorar após a implantação**: deriva de dados e de confiança, auditorias periódicas com rótulos humanos, comparação com sensores independentes e retreinamento versionado.

5.2.4 Por que 78% de acurácia não garante desempenho confiável

A acurácia é uma **média** sobre a distribuição da validação. Se a validação compartilha câmeras, ângulos, dias e condições com o treino, ela mede a capacidade de reconhecer cenas já vistas, e não de operar em condições novas. O número também não mostra **onde** estão os 22% de erro. As falhas sistemáticas observadas indicam que os erros se concentram justamente nas fatias mais críticas (noite, chuva, câmeras novas). Sob mudança de domínio, o desempenho em uma distribuição não é evidência sobre outra: em uma noite chuvosa numa câmera nova, a acurácia real pode ser muito inferior a 78%. Confiabilidade operacional exige avaliação por câmera, por condição e ao longo do tempo, além de monitoramento contínuo.

5.3 Limitações

1. Sem identificador de paciente, o agrupamento por hash perceptual reduz, mas não elimina, o vazamento entre pacientes.

2. A validação tem apenas 24 casos de COVID, e cada caso move o recall em 4,2 p.p.
3. Os resultados vêm de uma única semente e de uma única divisão.
4. Classe e fonte dos dados estão completamente confundidas (COVID vem de repositórios distintos de *Normal* e *Viral Pneumonia*).
5. A cGAN em 64×64 foi treinada com 82 radiografias reais de COVID, sem métrica de qualidade validada para imagens médicas e sem revisão clínica.
6. O baseline com transfer learning **não** reproduz a ResNet-18 treinada do zero do cenário; os números não são comparáveis aos 93%/61% do enunciado.
7. A amostra tem proporções artificiais (70/20/10), diferentes do dataset e de qualquer prevalência clínica.

Referências

Artigos

- ABNAR, S.; ZUIDEMA, W. Quantifying Attention Flow in Transformers. *Proceedings of ACL*, 2020.
- CHOWDHURY, M. E. H. et al. Can AI help in screening Viral and COVID-19 pneumonia? *IEEE Access*, v. 8, p. 132665–132676, 2020.
- DOSOVITSKIY, A. et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. *ICLR*, 2021.
- GOODFELLOW, I. et al. Generative Adversarial Nets. *NeurIPS*, 2014.
- HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep Residual Learning for Image Recognition. *CVPR*, 2016.
- MIRZA, M.; OSINDERO, S. Conditional Generative Adversarial Nets. *arXiv:1411.1784*, 2014.
- MIYATO, T. et al. Spectral Normalization for Generative Adversarial Networks. *ICLR*, 2018.
- RADFORD, A.; METZ, L.; CHINTALA, S. Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks. *ICLR*, 2016.
- RADFORD, A. et al. Learning Transferable Visual Models From Natural Language Supervision. *ICML*, 2021.
- RAHMAN, T. et al. Exploring the effect of image enhancement techniques on COVID-19 detection using chest X-ray images. *Computers in Biology and Medicine*, v. 132, 104319, 2021.
- ROFFO, G.; VINCIARELLI, A. Personality in Computational Advertising: A Benchmark. *International Workshop on Emotion and Sentiment in Social and Expressive Media (ESSEM)*, 2016.
- ZECH, J. R. et al. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: a cross-sectional study. *PLOS Medicine*, v. 15, n. 11, e1002683, 2018.

Datasets

- Car Accidents and Deformation Dataset (Annotated). Kaggle: `marslanarshad/car-accidents-and-deformation-datasetannotated`.
- ADS-16 Computational Advertising Dataset. Kaggle: `groffo/ads16-dataset`.
- Images Dataset. Kaggle: `pavansanagapati/images-dataset`.
- COVID-19 Radiography Database. Kaggle: `tawsifurrahman/covid19-radiography-database`.

Outras fontes

- Meegle. Transfer Learning for Traffic Analysis. Disponível em: https://www.meegle.com/en_us/topics/transfer-learning/transfer-learning-for-traffic-analysis.
- Documentação do PyTorch e do torchvision: https://pytorch.org/docs/.