Deep Learning and Computer Vision

Relatório das Atividades 1 a 4

Gabriel Aguiar Aquino

11 de outubro de 2026

Sumário

Declaração de uso de inteligência artificial **3**

1 Introdução **4**
1.1 Ambiente de execução . . . 4
1.2 Organização do relatório . . . 4

2 Atividade 1 — Vision Transformer para Severidade de Acidentes **5**
2.1 Objetivo . . . 5
2.2 Dados . . . 5
2.3 Método . . . 6
2.4 Resultados . . . 6
2.5 Interpretabilidade: Attention Rollout . . . 7
2.6 Discussão . . . 8
2.7 Limitações . . . 8

3 Atividade 2 — Reconhecimento Semântico em Publicidade Visual com CLIP **10**
3.1 Objetivo . . . 10
3.2 Dados . . . 10
3.3 Método . . . 10
3.4 Resultados . . . 10
3.4.1 Escolha do limiar . . . 10
3.4.2 Ranking de conceitos (limiar 0,28) . . . 11
3.4.3 Busca semântica . . . 12
3.5 Discussão . . . 13
3.6 Limitações . . . 14

4 Atividade 3 — Classificador com CNN Pré-treinada **15**
4.1 Objetivo . . . 15
4.2 Dados . . . 15
4.3 Método . . . 15
4.4 Resultados . . . 16
4.5 Análise crítica: vazamento por imagens duplicadas . . . 17
4.6 Propostas de melhoria . . . 18
4.7 Limitações . . . 18

5 Atividade 4 — Estudos de Caso **19**

Referências **20**

Declaração de uso de inteligência artificial

Este trabalho foi desenvolvido com o apoio de uma ferramenta de inteligência artificial generativa, o **Claude Code** (Anthropic), utilizado como assistente de programação e de redação.

Como a ferramenta foi utilizada

- Geração e revisão de código dos notebooks (carregamento de dados, treinamento, avaliação e visualização), a partir dos enunciados das atividades.
- Identificação de erros e problemas metodológicos, como vazamento de dados, critérios de seleção de checkpoint e agrupamento de imagens quase idênticas.
- Organização e redação deste relatório a partir das saídas efetivamente registradas nos notebooks, além do script que consolida o relatório em PDF.

Responsabilidades do autor

- Execução dos notebooks no Google Colab e conferência das saídas.
- Revisão crítica do código, das análises e do texto, além das decisões finais sobre o que entra no trabalho.
- Responsabilidade integral pelo conteúdo entregue.

Integridade dos resultados

Todos os números, tabelas e figuras de resultados apresentados neste relatório foram extraídos das saídas das execuções dos notebooks; nenhum valor experimental foi produzido ou estimado pela ferramenta de IA. Quando uma execução apresentou problema metodológico, o problema é relatado em vez de omitido.

1 Introdução

Este relatório reúne as quatro atividades práticas de Visão Computacional e Deep Learning desenvolvidas no repositório `computer-vision-p1`. Cada atividade foi implementada como um notebook executável no Google Colab e explora uma família diferente de técnicas.

Atividade	Tema	Técnica principal	Dataset
1	Classificação de severidade de acidentes	Vision Transformer (do zero e pré-treinado) e ResNet-18	Car Accidents and Deformation Dataset (CADD)
2	Reconhecimento semântico em publicidade	CLIP (ViT-B/32) em regime *zero-shot*	ADS-16
3	Classificador com CNN pré-treinada	ResNet-50 com extração de características	Images Dataset (7 classes)
4	Estudos de caso	ResNet-18 com transfer learning e GAN condicional; análise de transfer learning em tráfego urbano	COVID-19 Radiography Database

1.1 Ambiente de execução

Todos os notebooks foram executados no Google Colab com GPU NVIDIA Tesla T4, PyTorch 2.11 e torchvision 0.26 (CUDA 12.8). Os datasets são públicos e foram obtidos pela API oficial do Kaggle. Cada notebook fixa a semente 42 para Python, NumPy e PyTorch.

1.2 Organização do relatório

Cada capítulo segue a mesma estrutura: objetivo, dados, método, resultados e discussão crítica, incluindo as limitações. Os números citados são os registrados nas saídas dos notebooks versionados no repositório, e as figuras foram extraídas dessas mesmas saídas.

Ao longo do relatório, adota-se uma postura crítica em relação aos próprios resultados: métricas muito altas ou muito baixas são investigadas, e problemas de protocolo (por exemplo, seleção de modelo no mesmo conjunto usado para reportar o desempenho) são apontados explicitamente.

2 Atividade 1 — Vision Transformer para Severidade de Acidentes

Notebook: `atividade-1-projeto-livre/vit_accident_severity_colab.ipynb`.

2.1 Objetivo

Construir um pipeline de classificação de imagens em cinco níveis de severidade de acidentes de trânsito e comparar três modelos:

1. **ResNet-18** pré-treinada no ImageNet (baseline convolucional, *fine-tuning* completo);
2. **Vision Transformer (ViT) implementado e treinado do zero**;
3. **ViT-B/16 pré-treinado** no ImageNet-1k (*fine-tuning* completo).

Também se investiga a interpretabilidade do ViT por meio de **Attention Rollout** (Abnar & Zuidema, 2020), comparando os mapas de atenção com as *bounding boxes* anotadas.

2.2 Dados

O **Car Accidents and Deformation Dataset (CADD)** traz anotações no formato YOLO (detecção de objetos) em cinco classes: *Sem Acidente*, *Acidente Leve*, *Acidente Moderado*, *Acidente Severo* e *Perda Total*.

Rótulo por imagem. Como a tarefa é de classificação, cada imagem recebe a classe **mais severa** entre os objetos anotados (`label = max(class_ids)`). Essa é uma simplificação: uma imagem com um carro intacto e outro com perda total é rotulada como *Perda Total*.

Inspeção. Foram encontradas 1.221 imagens válidas com rótulo; duas imagens da validação original foram descartadas por não terem arquivo de rótulo.

Divisão com controle de vazamento. O dataset contém cópias aumentadas das mesmas fotos (sufixos como `_flip`, `_flip30`, `_flip70`). Na divisão original do dataset, **70 grupos** de imagens apareciam simultaneamente no treino e na validação, o que caracteriza vazamento. O notebook remove esses sufixos para obter um identificador de grupo (1.016 grupos) e refaz a divisão 80/20 **por grupo**, garantindo que nenhuma foto e suas variações apareçam nos dois conjuntos.

Classe	Treino	Validação
Sem Acidente	48	17
Acidente Leve	245	59
Acidente Moderado	253	78
Acidente Severo	163	40
Perda Total	271	47
Total	**980**	**241**

A classe *Sem Acidente* é a menos representada. Para compensar, a função de perda usa **pesos de classe** inversamente proporcionais à frequência (de 0,72 para *Perda Total* a 4,08 para *Sem Acidente*) e **label smoothing** de 0,1.

2.3 Método

Entrada de 224×224 com normalização do ImageNet. No treino, aplicou-se *data augmentation* com `RandomResizedCrop` (escala 0,7–1,0), espelhamento horizontal, rotação de ±15° e `ColorJitter`. Todos os modelos usam AdamW e mixed precision na GPU.

Modelo	Inicialização	Épocas	LR	Agenda de LR
ResNet-18	ImageNet	5	3e-4	Cosseno
ViT do zero (6 blocos, 6 cabeças, dim. 384, patch 16)	Aleatória	20	3e-4	Warmup linear (3 ép.) + cosseno
ViT-B/16	ImageNet-1k	10	1e-4	Warmup linear (2 ép.) + cosseno

O ViT do zero foi implementado explicitamente: *patch embedding* por convolução com *stride* igual ao *patch*, token `[CLS]`, *embeddings* posicionais aprendidos e blocos *pre-norm* com atenção multi-cabeça calculada como $\mathrm{softmax}(QK^\top/\sqrt{d_k})V$. Em todos os modelos, o melhor estado foi escolhido pela **macro F1 de validação**.

2.4 Resultados

Modelo	Melhor época	Acurácia	Macro precisão	Macro recall	Macro F1
ResNet-18 (ImageNet)	3	0,527	0,539	0,550	0,518
ViT do zero	19	0,253	0,316	0,290	0,253
ViT-B/16 (ImageNet-1k)	8	**0,568**	**0,578**	**0,606**	**0,576**

Como referências mínimas: um classificador que sempre prevê a classe mais frequente da validação (*Acidente Moderado*, 78 de 241) obtém **0,324** de acurácia, e o acaso com cinco classes fica em torno de 0,20.

F1 por classe do ViT-B/16 pré-treinado: *Sem Acidente* 0,571; *Leve* 0,617; *Moderado* 0,496; *Severo* 0,438; *Perda Total* 0,756.

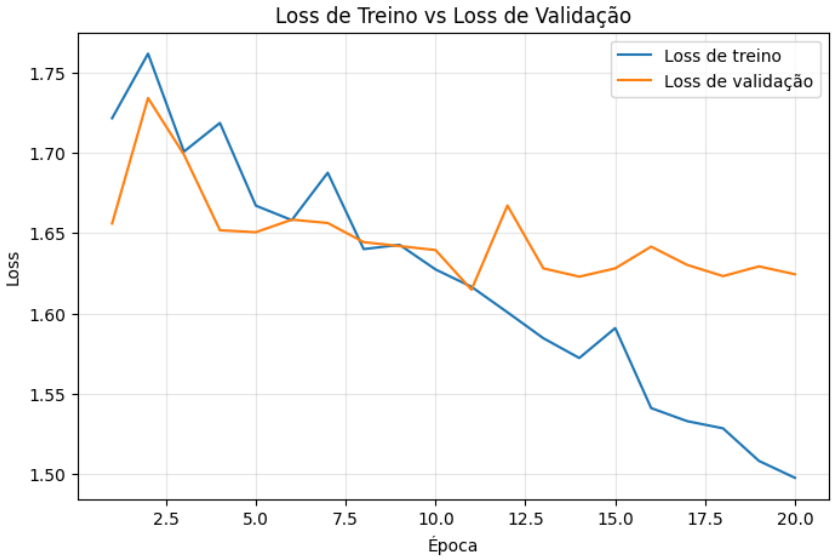


Figura 1: Loss de treino e de validação do ViT treinado do zero.

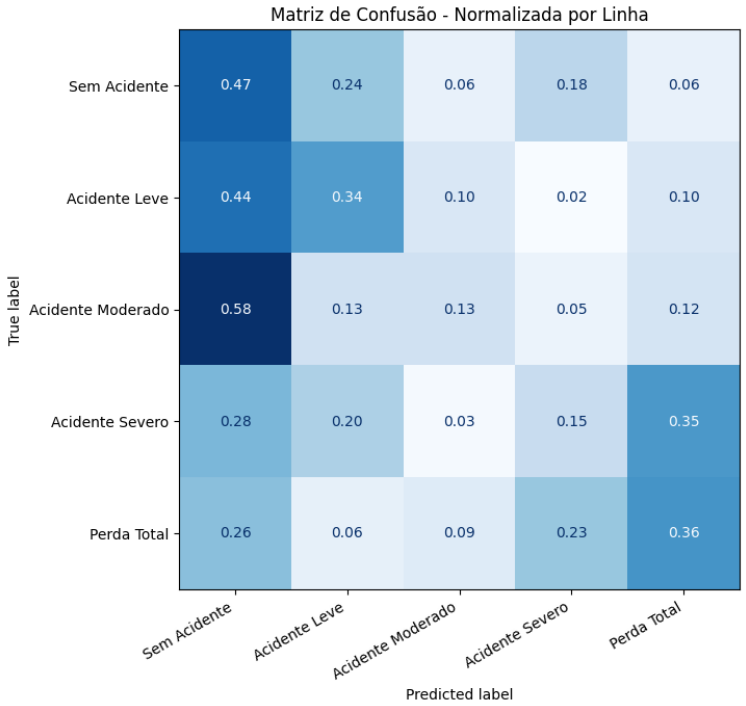


Figura 2: Matriz de confusão normalizada por linha do ViT treinado do zero (validação).

2.5 Interpretabilidade: Attention Rollout

O Attention Rollout propaga as matrizes de atenção (média das cabeças, com a identidade somada para representar as conexões residuais) por todas as camadas e mede quanto cada *patch* contribui para o token `[CLS]`. A figura compara a atenção da última camada, o rollout e as *bounding boxes* reais.

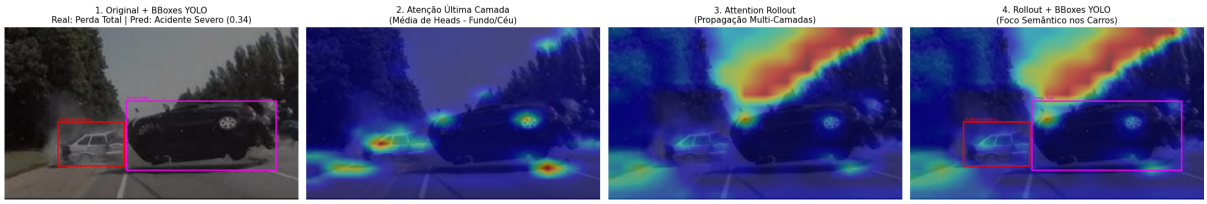


Figura 3: Attention Rollout do ViT treinado do zero em uma imagem de validação (rótulo real *Perda Total*, previsto *Acidente Severo*).

Leitura crítica. No exemplo acima, o rollout concentra a atenção na faixa de **céu e árvores** no canto superior direito, e não nos veículos delimitados pelas caixas. Isso é coerente com o baixo desempenho do ViT do zero: o modelo não aprendeu a focar nos danos e parece usar pistas de fundo. A legenda "Foco Semântico nos Carros" usada no notebook **não** é sustentada por esse exemplo. O rollout foi calculado apenas para o ViT do zero; o ViT-B/16 do torchvision não expõe os pesos de atenção, de modo que a análise não foi repetida para o melhor modelo.

2.6 Discussão

- **ViT do zero não aprende com ~1.000 imagens.** O ViT treinado do zero ficou **abaixo da baseline da classe majoritária** (0,253 contra 0,324). A acurácia de treino chegou a apenas 0,40 em 20 épocas, o que indica **subajuste**, e não sobreajuste. Transformers não têm os vieses indutivos das convoluções (localidade e equivariância à translação) e precisam de muito mais dados ou de pré-treinamento. A matriz de confusão mostra previsões espalhadas, com forte tendência a *Sem Acidente*, provavelmente puxada pelo maior peso dessa classe na perda.
- **Pré-treinamento é o fator decisivo.** O ViT-B/16 pré-treinado teve o melhor resultado (macro F1 0,576), seguido da ResNet-18 (0,518). Com pré-treinamento, o Transformer supera a CNN mesmo com poucos dados.
- **Sobreajuste nos modelos pré-treinados.** O ViT-B/16 atingiu 0,894 de acurácia no treino contra 0,568 na validação. A lacuna de ~33 p.p. sugere que regularização adicional, congelamento parcial ou mais dados ajudariam.
- **Classes intermediárias são as mais difíceis.** *Moderado* e *Severo* têm os menores F1, o que é esperado em uma escala ordinal com fronteiras subjetivas entre níveis vizinhos.

2.7 Limitações

1. **Seleção otimista do checkpoint.** O melhor estado de cada modelo foi escolhido pela macro F1 na **mesma validação** usada para reportar os resultados. Os números acima tendem, portanto, a ser otimistas; o correto seria separar uma validação interna para seleção ou usar um conjunto de teste independente.
2. **Uma única semente e uma única divisão.** Com 241 imagens de validação (17 de *Sem Acidente*), as métricas têm variância alta; diferenças de poucos pontos entre modelos não são conclusivas.
3. **Rótulo por agregação.** A regra "classe mais severa" ignora a presença de múltiplos veículos e transforma um problema de detecção em classificação.
4. **Agrupamento heurístico.** O controle de vazamento depende de sufixos de

nome de arquivo; cópias aumentadas com outros nomes não seriam detectadas.

5. **Reprodutibilidade parcial.** O notebook usa `cudnn.benchmark = True` e `cudnn.deterministic = False`, de modo que reexecuções na GPU podem variar ligeiramente.
6. **Interpretabilidade limitada.** Apenas três exemplos de rollout, todos do modelo mais fraco.

3 Atividade 2 — Reconhecimento Semântico em Publicidade Visual com CLIP

Notebook: `atividade-2-clip-publicidade/clip_semantic_advertising_colab.ipynb`.

3.1 Objetivo

Usar o **CLIP** (*Contrastive Language-Image Pre-training*, OpenAI) em regime estritamente **zero-shot** (sem treinamento, sem *fine-tuning* e sem atualização de pesos) para:

1. medir a presença de **20 conceitos semânticos** em anúncios publicitários e ordená-los por frequência;
2. implementar uma **busca semântica por texto** (*zero-shot retrieval*) e analisar oito consultas que variam de genéricas a abstratas.

3.2 Dados

O **ADS-16 Computational Advertising Dataset** foi baixado do Kaggle (`groffo/ads16-dataset`). A varredura recursiva encontrou **2.697 imagens** distribuídas em **260 pastas**. Há dois tipos de pasta: as numeradas de 1 a 20, com cerca de 15 anúncios cada, e pastas identificadas por código de usuário com sufixo `IM-POS`/`IM-NEG`, com 10 a 20 imagens. O notebook trata o nome da pasta como "categoria"; essa informação serve apenas para exibição, pois a tarefa não usa rótulos.

3.3 Método

Etapa	Implementação
Modelo	CLIP `ViT-B/32`, `model.eval()` e `torch.no_grad()` em toda a inferência
Embeddings de imagem	Encoder visual do CLIP, 512 dimensões, normalização L_2
Conceitos	20 conceitos (ex.: *a car*, *a person*, *text and logo*, *a luxury product*)
Prompt	Template contextual `"an advertisement featuring {}"`
Similaridade	$S = X_{img} X_{txt}^{\top}$ (cosseno, pois os vetores têm norma 1), matriz 2.697 × 20
Presença de conceito	Similaridade $\geq$ limiar operacional
Busca	Texto → embedding normalizado → produto escalar com todas as imagens → top-5

A similaridade de cosseno do CLIP **não é uma probabilidade**: ela mede proximidade angular no espaço multimodal, e qualquer limiar de "presença" é uma regra heurística.

3.4 Resultados

3.4.1 Escolha do limiar

Limiar	Conceitos por imagem (média)	Imagens sem nenhum conceito
0,20	7,89	12,3%
0,25	0,44	84,2%
0,28	**0,04**	**98,1%**
0,30	0,01	99,6%
0,35	0,00	100,0%

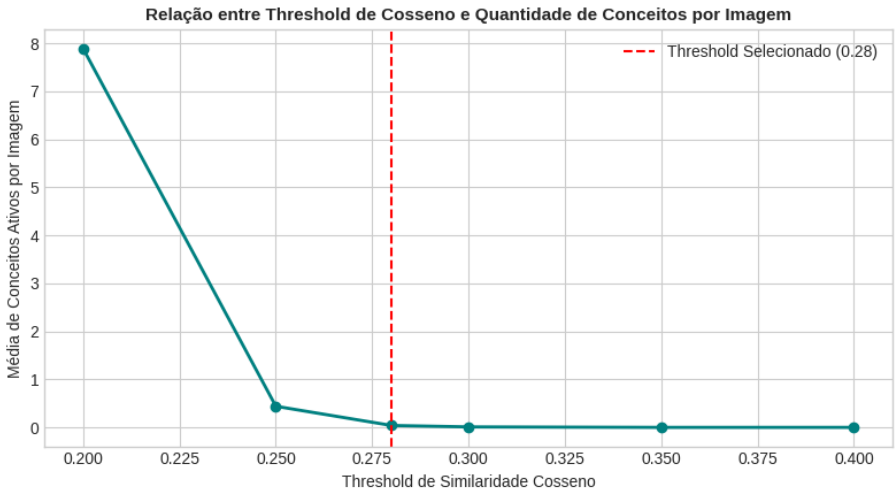


Figura 4: Média de conceitos detectados por imagem em função do limiar.

O notebook fixou o limiar em **0,28**. A curva mostra que as similaridades se concentram em uma faixa muito estreita (aproximadamente 0,18–0,34): entre 0,20 e 0,25 a média despenca de quase 8 para menos de 0,5 conceito por imagem.

3.4.2 Ranking de conceitos (limiar 0,28)

Posição	Conceito	Similaridade média	Imagens acima do limiar	Frequência
1	a fashion product	0,1996	18	0,67%
2	a person	0,2076	9	0,33%
3	a household product	0,1986	9	0,33%
4	a woman	0,1958	8	0,30%
5	a luxury product	0,2035	7	0,26%
…	…	…	…	…
20	a building	0,1765	0	0,00%

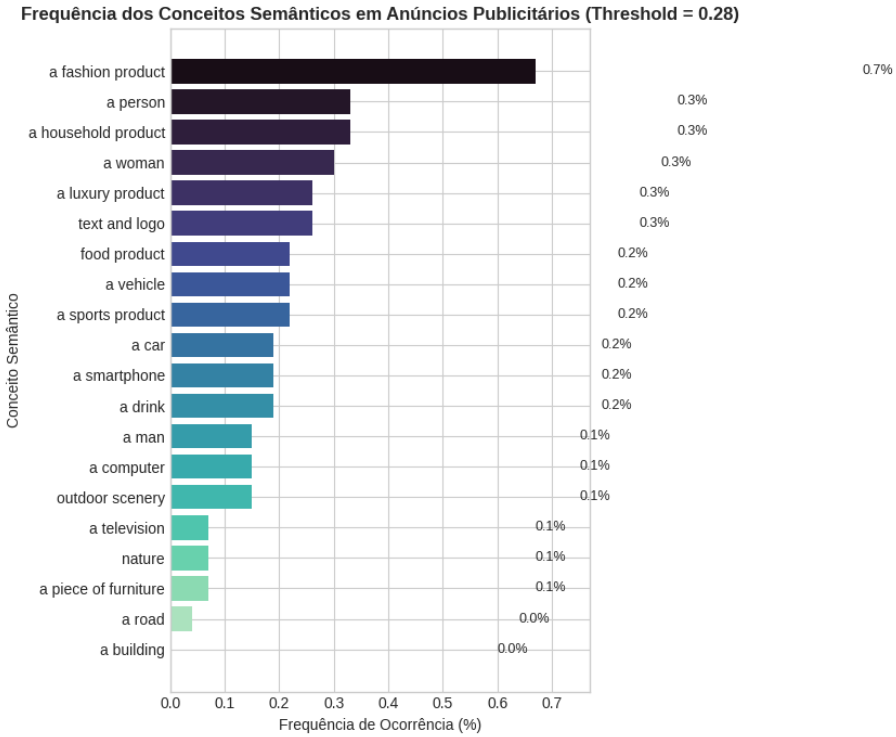


Figura 5: Frequência dos 20 conceitos no corpus com limiar 0,28.

3.4.3 Busca semântica

Foram executadas oito consultas: genéricas (*a product advertisement*), concretas (*a person*, *a car*), específicas (*a person using a smartphone*, *a luxury car in an urban environment*, *a cold drink being advertised*) e abstratas (*a premium lifestyle*, *an advertisement designed to attract attention*). Os escores do top-5 ficaram entre 0,264 e 0,338.



Figura 6: Top-5 para a consulta concreta “a car”.

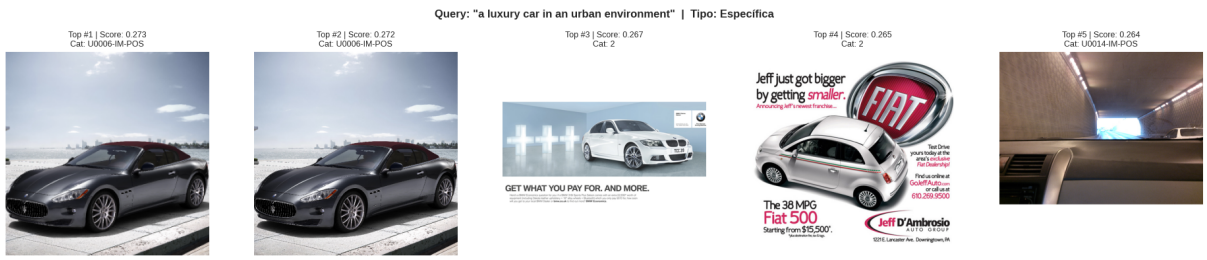


Figura 7: Top-5 para a consulta específica “a luxury car in an urban environment”.

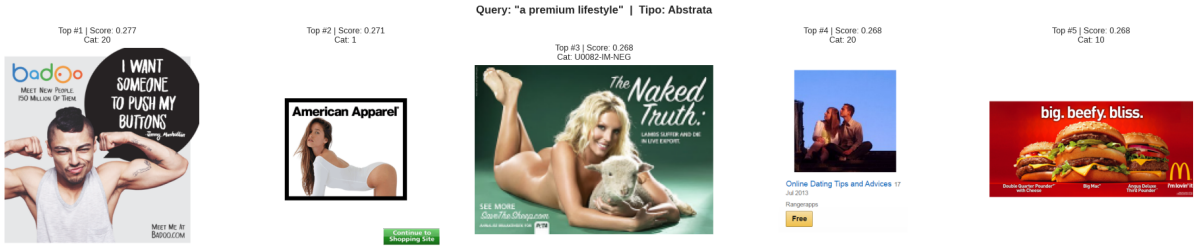


Figura 8: Top-5 para a consulta abstrata “a premium lifestyle”.

O que as figuras mostram (inspeção visual das saídas):

- **Consultas concretas de objeto funcionam bem.** Em *a car*, as cinco imagens são anúncios automotivos (Fiat 500, BMW, acessórios Raven, peças Renault). Uma delas, porém, é um anúncio **apenas de texto** (“Cheapest Car Parts Online”), sem nenhum carro: o CLIP também “lê” o texto da imagem.
- **Consultas específicas funcionam parcialmente.** *A luxury car in an urban environment* recupera um Maserati e um BMW, mas o fundo urbano raramente está presente; a 5ª imagem é o interior de um carro em um túnel.
- **Consultas abstratas são fracas.** *A premium lifestyle* retorna um anúncio do aplicativo de relacionamento Badoo, um da American Apparel, uma campanha da PETA, um anúncio de app de encontros e um do McDonald’s. Apenas parte desses resultados pode ser associada a “estilo de vida premium”.

3.5 Discussão

- **O limiar 0,28 é restritivo demais para contar conceitos.** Com ele, 98,1% das imagens não têm nenhum conceito, e o conceito mais frequente aparece em apenas 18 de 2.697 anúncios. O ranking passa a depender de poucas imagens e é instável: mudar a ordem de alguns poucos anúncios altera as posições. Note que a ordem por **similaridade média** é diferente (*a person* teria a maior média, 0,2076). Alternativas mais robustas seriam: limiar por conceito (por exemplo, um percentil da distribuição de cada conceito), atribuição *top-k* por imagem ou comparação relativa entre conceitos (softmax sobre os 20 *prompts*).
- **Fenômeno de *hubness*.** Um pequeno conjunto de imagens domina os resultados de consultas sem relação entre si. O anúncio do **Fiat 500** aparece no top-5 de **6 das 8** consultas (inclusive *a person* e *a person using a smartphone*), o do **Badoo** em 5 das 8, e o da **Kaspersky** em 4. Esses “hubs” são anúncios prototípicos (produto, pessoa e texto em destaque) que ficam próximos de muitos textos no espaço do CLIP. Isso explica por que a busca parece razoável em consultas genéricas e falha em consultas que exigem detalhes.
- **Efeito do template de prompt.** A função de busca aplica o mesmo template dos conceitos às consultas. Assim, *a product advertisement* se torna “an advertisement featuring a product advertisement”, e todas as consultas são puxadas na direção de “anúncio típico”, o que reforça o *hubness*. Comparar a busca com e sem o template seria um experimento simples e informativo.
- **Leitura de texto (OCR implícito).** O CLIP associa palavras escritas na imagem ao conceito, como em “Car Parts”, “Smartphone offers” e “Freshly Brewed Coffee” (este último aparece em *a cold drink being advertised*). Isso é útil para anúncios, mas também é uma vulnerabilidade conhecida a “ataques tipográficos”.

- **Duplicatas no corpus.** Imagens idênticas aparecem em posições consecutivas (o Maserati em *luxury car* e as latas de refrigerante em *cold drink*). Elas ocupam vagas do top-5 e inflam contagens; uma deduplicação por hash antes da indexação resolveria.
- **Divergência com a tabela qualitativa do notebook.** A tabela de "comportamento observado" do notebook descreve resultados mais favoráveis do que os exibidos nas figuras (por exemplo, "precisão de 100%" para *a person*, cujo top-5 inclui o anúncio do Fiat 500 sem pessoa visível). Este relatório adota a descrição baseada nas figuras efetivamente geradas.

3.6 Limitações

1. **Sem *ground truth*.** Não há anotação de presença de conceitos nem relevância por consulta; toda a avaliação é qualitativa. Uma rotulagem manual de uma amostra permitiria medir *precision@k*.
2. **Limiar heurístico global**, aplicado igualmente a conceitos com distribuições de similaridade diferentes.
3. **Vieses do pré-treinamento.** O CLIP herda associações culturais dos dados da web (o que é "luxo", "beleza", "atenção"), o que afeta diretamente as consultas abstratas.
4. **Embedding global.** Um único vetor por imagem não localiza objetos; composições como "pessoa *usando* smartphone" são resolvidas apenas aproximadamente.

4 Atividade 3 — Classificador com CNN Pré-treinada

Notebook: `atividade-3-cnn-pre-treinada/cnn_feature_extraction_colab.ipynb`.

4.1 Objetivo

Construir um baseline de **transfer learning por extração de características**: uma ResNet-50 pré-treinada no ImageNet é usada como extratora congelada, e apenas uma nova camada linear de classificação é treinada. O baseline não usa *data augmentation*, para servir de referência limpa às propostas de melhoria.

4.2 Dados

Images Dataset (Kaggle, `pavansanagapati/images-dataset`): 3.606 arquivos de imagem (`.jpg`, `.png`, `.bmp`) em 7 classes, sem nenhum arquivo corrompido.

Classe	Total	Treino	Validação
bike	730	584	146
cars	840	672	168
cats	404	323	81
dogs	404	323	81
flowers	420	336	84
horses	404	323	81
human	404	323	81
Total	**3.606**	**2.884**	**722**

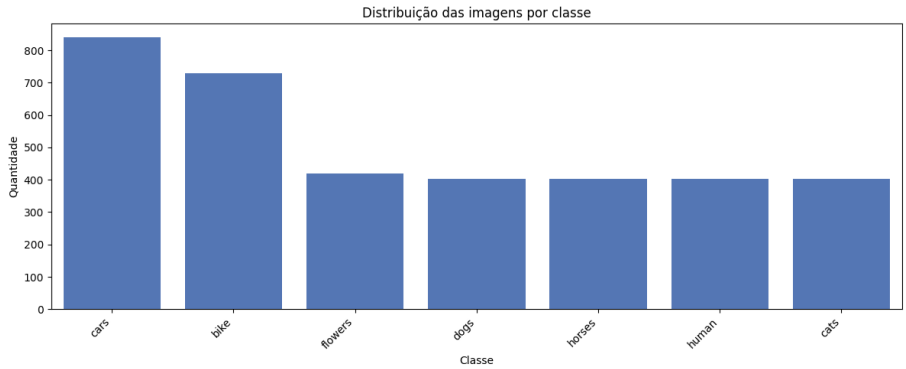


Figura 9: Distribuição das imagens por classe.

A divisão é estratificada (80/20, semente 42).

4.3 Método

Item	Configuração
Backbone	ResNet-50, pesos `ResNet50_Weights.DEFAULT` (ImageNet), **todas as camadas congeladas**
Cabeça	`Linear(2048 → 7)`: 14.343 parâmetros treináveis de 23,5 milhões

Item	Configuração
Pré-processamento	`Resize(224)`, `CenterCrop(224)`, normalização ImageNet; sem augmentation
Treinamento	Entropia cruzada, Adam (lr 1e-3) apenas na cabeça, lote 32, 10 épocas
Seleção	Melhor acurácia de validação

4.4 Resultados

Época	Loss treino	Acurácia treino	Loss validação	Acurácia validação
1	0,4452	0,9286	0,1321	0,9889
5	0,0224	0,9976	0,0274	0,9972
10	0,0099	0,9990	0,0134	**1,0000**

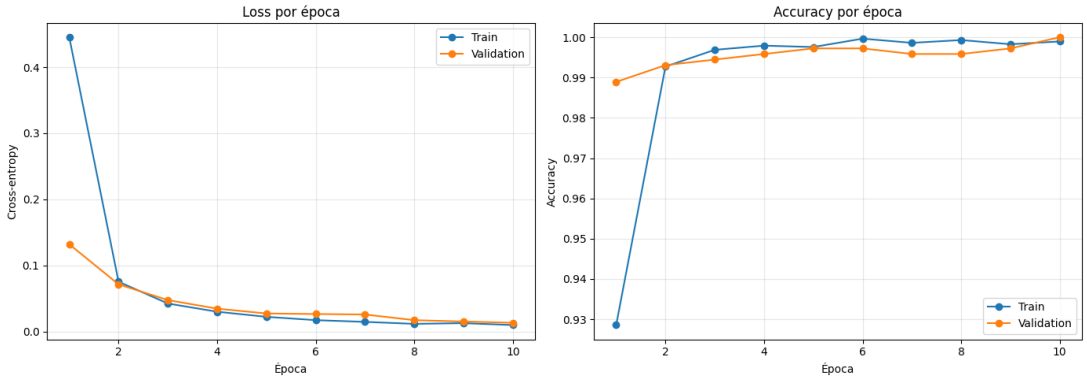


Figura 10: Curvas de loss e acurácia por época.

Na época 10, o modelo classificou corretamente **as 722 imagens de validação**: acurácia, precisão, recall e F1 iguais a 1,00 em todas as classes, sem nenhum erro a exibir.

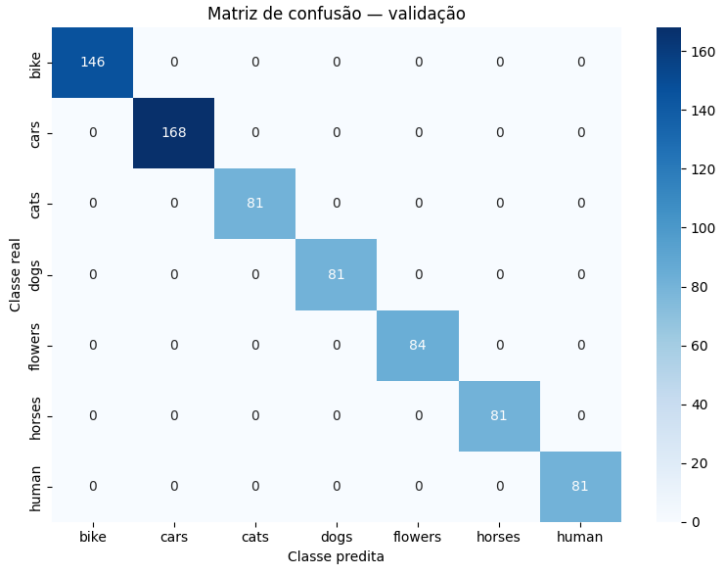


Figura 11: Matriz de confusão na validação.

4.5 Análise crítica: vazamento por imagens duplicadas

Um resultado perfeito exige verificação. Os caminhos listados no notebook já indicavam duas estruturas paralelas (por exemplo, `data/horses/...` e `data/data/bike/...`). Para checar, o dataset foi baixado novamente e a divisão do notebook foi reproduzida com as mesmas sementes, calculando o hash MD5 de cada arquivo:

Verificação	Resultado
Pastas `data/<classe>` e `data/data/<classe>`	mesmas contagens por classe (ex.: 420 + 420 em *cars*)
Conteúdos distintos (MD5) entre os 3.606 arquivos	**1.764**
Arquivos que têm ao menos uma cópia idêntica	**3.606 (100%)**
Imagens de validação com cópia exata no treino	**568 de 722 (78,7%)**
Imagens de validação sem cópia no treino (MD5 nem hash perceptual)	154

Ou seja, o dataset vem **inteiramente duplicado**. Como a divisão foi feita por arquivo, quase 79% da validação consiste em imagens que o classificador viu no treino. A acurácia de 100% sobre 722 imagens **não é uma estimativa válida de generalização**.

Ainda assim, há uma evidência útil nas saídas: como o modelo não errou nenhuma imagem de validação, também acertou as **154 imagens sem cópia no treino**. Para 154 acertos em 154, o intervalo de confiança de Wilson (95%) para a acurácia é aproximadamente **[0,976; 1,000]**. A tarefa é de fato fácil para features do ImageNet: as sete classes (carros, bicicletas, cães, gatos, cavalos, flores e pessoas) correspondem a conceitos amplamente representados no pré-treinamento e tendem a ser linearmente separáveis no espaço de 2.048 dimensões da ResNet-50. As curvas, com acurácia de validação de 0,989 já na primeira época, são coerentes com essa leitura.

Correção recomendada: remover duplicatas por MD5 **antes** da divisão (ou dividir por grupo de conteúdo), reexecutar o experimento e reportar a acurácia sobre as ~1.764 imagens distintas.

4.6 Propostas de melhoria

O notebook discute técnicas para experimentos posteriores, mantendo o baseline intocado:

Técnica	Benefício esperado	Risco
Augmentation geométrica (flip horizontal, rotações e crops pequenos)	Variedade de enquadramento; menos sobreajuste	Alterar a semântica de objetos orientados
Augmentation de cor (`ColorJitter` conservador)	Robustez a iluminação e câmera	Apagar pistas de cor relevantes
Variação de escala (`RandomResizedCrop` moderado)	Robustez a distância e enquadramento	Cortar o objeto
Normalização ImageNet	Compatibilidade com o pré-treinamento	Já utilizada; não é augmentation

Diante do vazamento identificado, a prioridade é outra: **deduplicar e reavaliar**. Com um baseline já próximo de 100%, ganhos de augmentation só serão mensuráveis com um conjunto de avaliação mais difícil, por exemplo com imagens de outra fonte.

4.7 Limitações

1. Vazamento por duplicatas, descrito acima.
2. Seleção do checkpoint pela acurácia na mesma validação usada para reportar o resultado.
3. Apenas acurácia e matriz de confusão; com classes desbalanceadas (*cars* tem o dobro de *cats*), métricas por classe e macro F1 deveriam ser padrão (aqui todas valem 1,0).
4. Uma única semente e nenhum conjunto de teste independente.

5 Atividade 4 — Estudos de Caso

(rascunho)

Referências

Artigos

- ABNAR, S.; ZUIDEMA, W. Quantifying Attention Flow in Transformers. *Proceedings of ACL*, 2020.
- CHOWDHURY, M. E. H. et al. Can AI help in screening Viral and COVID-19 pneumonia? *IEEE Access*, v. 8, p. 132665–132676, 2020.
- DOSOVITSKIY, A. et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. *ICLR*, 2021.
- GOODFELLOW, I. et al. Generative Adversarial Nets. *NeurIPS*, 2014.
- HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep Residual Learning for Image Recognition. *CVPR*, 2016.
- MIRZA, M.; OSINDERO, S. Conditional Generative Adversarial Nets. *arXiv:1411.1784*, 2014.
- MIYATO, T. et al. Spectral Normalization for Generative Adversarial Networks. *ICLR*, 2018.
- RADFORD, A.; METZ, L.; CHINTALA, S. Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks. *ICLR*, 2016.
- RADFORD, A. et al. Learning Transferable Visual Models From Natural Language Supervision. *ICML*, 2021.
- RAHMAN, T. et al. Exploring the effect of image enhancement techniques on COVID-19 detection using chest X-ray images. *Computers in Biology and Medicine*, v. 132, 104319, 2021.
- ROFFO, G.; VINCIARELLI, A. Personality in Computational Advertising: A Benchmark. *International Workshop on Emotion and Sentiment in Social and Expressive Media (ESSEM)*, 2016.
- ZECH, J. R. et al. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: a cross-sectional study. *PLOS Medicine*, v. 15, n. 11, e1002683, 2018.

Datasets

- Car Accidents and Deformation Dataset (Annotated). Kaggle: `marslanarshad/car-accidents-and-deformation-datasetannotated`.
- ADS-16 Computational Advertising Dataset. Kaggle: `groffo/ads16-dataset`.
- Images Dataset. Kaggle: `pavansanagapati/images-dataset`.
- COVID-19 Radiography Database. Kaggle: `tawsifurrahman/covid19-radiography-database`.

Outras fontes

- Meegle. Transfer Learning for Traffic Analysis. Disponível em: https://www.meegle.com/en_us/topics/transfer-learning/transfer-learning-for-traffic-analysis.
- Documentação do PyTorch e do torchvision: https://pytorch.org/docs/.